1. 构建首个面向机场场面监控的 AiOIR 数据集，填补研究空白。

2. 提出基于傅里叶变换的域适应方法，突破合成数据虚实迁移瓶颈。

3. 建立“信号复原-语义感知-跨域泛化”多维基准评估体系，量化数据应用价值。

报告正文

（一） 立项依据与研究内容（建议 8000 字以下（不包括文献））

1. **项目的立项依据**（【理工医科】研究意义、国内外研究现状及发展动态分析，需结合科学研究发展趋势来论述科学意义；或结合国民经济和社会发展中迫切需要解决的关键科技问题来论述其应用前景。附主要参考文献目录【哲学社会学科】国内外相关研究的学术史梳理及研究动态；本课题相对于已有研究的独到学术价值和应用价值等。附主要参考文献目录）

1.1 研究背景

1.1.1 空中交通流量激增背景下的机场运行安全挑战

根据中国民用航空局发布的《2024 年民航行业发展统计公报》，我国 2024 年民航全行业完成运输总周转量 1485.17 亿吨公里，比上年增长 25.0%，国内航线完成运输总周转量 975.65 亿吨公里，比上年增长 12.5%；2024 年全行业完成旅客运输量 73021.33 万人次，比上年增长 17.9%；国际航线完成旅客运输量 6555.55 万人次，比上年增长 125.6%[1]。民航行业发展势头旺盛，空中交通流量渐增，机场场面调度压力增大。



图 1.1 2020-2024 年民航运输总周转量

为了确保机场地面和附近空域的绝对安全与高效运行，机场塔台的空中交通管制员（Air Traffic Controller）需要基于机场场面监控、监视雷达等数据发布精确指令，指挥飞机的起飞、降落、滑行以及地面车辆的移动，严防飞机之间、飞机与车辆在跑道和滑行道上发生碰撞，同时协调飞行顺序，保持场面调度和空中交通的有序和流畅。传统的先进场面活动引导与控制系统（A-SMGCS, Advanced Surface Movement Guidance and Control System）是一个集成了多种监视技术的综合系统，旨在为机场塔台的空中交通管制员提供机场场面上所有飞机和车辆的实时位置和识别信息，是空中交通管理（ATM, Air Traffic Management）的基石，其提供的实时态势感知能力是保障空中交通安全与效率的前提[2]。空中交通管制（Air Traffic Control）依赖一次雷达和二次监视雷达进行目标定位与识别。然而，随着全球航空业务量的激增以及对机场运行安全稳定的极致追求，单一依赖雷达的模式已捉襟见肘。

1.1.2 视觉感知：雷达系统的有力补充

传统空中交通管制主要依赖雷达系统进行广域监视，但是雷达仅能提供运动学参数，缺

乏对航空器姿态、跑道异物及关键保障节点的语义感知能力，难以支撑全流程精细化管控；此外，其低刷新率、场面盲区及多径效应等物理局限日益凸显，无法提供高密度航班流与智慧机场建设的极致安全追求。近年来，计算机视觉技术凭借高分辨率、实时性强及语义信息丰富的优势，成为弥补雷达短板的关键。引入基于计算机视觉的智能监控，不仅能有效覆盖雷达盲区，更能通过细粒度特征识别实现对潜在安全隐患的早期预警。因此，构建“雷达引导+视觉感知”的异构融合监控体系，是突破当前空管运行瓶颈、提升复杂环境下安全与效率的核心路径。

在先进场面活动引导与控制系统中，高清视频监控网络被大规模部署于机坪、滑行道和跑道区域。这些视觉系统为管制员提供直观的视觉信息，同时是下一代智能化空中交通管制技术的核心数据来源[3]。一个革命性的趋势是远程塔台的兴起：远程塔台利用高清摄像头、全景拼接和增强现实技术，使管制员得以在远离机场的控制中心指挥航班。在这种模式下，摄像机捕捉到的图像质量与管制员的视觉认知效能密切相关，视觉系统的可靠性直接决定了运行安全。同时，场面监控是高级人工智能任务的输入源，基于计算机视觉的自动化系统正被广泛研究和应用，包括：

- **机坪目标跟踪**：实时跟踪飞机、地面服务车辆、工作人员，以优化调度和防止碰撞。
- **外来物（FOD）检测**：利用 YOLO 等深度学习模型自动检测跑道上的异物（如螺栓、碎屑），防止其被吸入发动机造成严重事故[4]。据统计，FOD 每年造成的经济损失高达上百亿美元[5]。
- **飞机识别与验证**：在繁忙空域，利用 AI 赋能的摄像头辅助验证雷达数据，识别未经授权的飞行器（如无人机）。

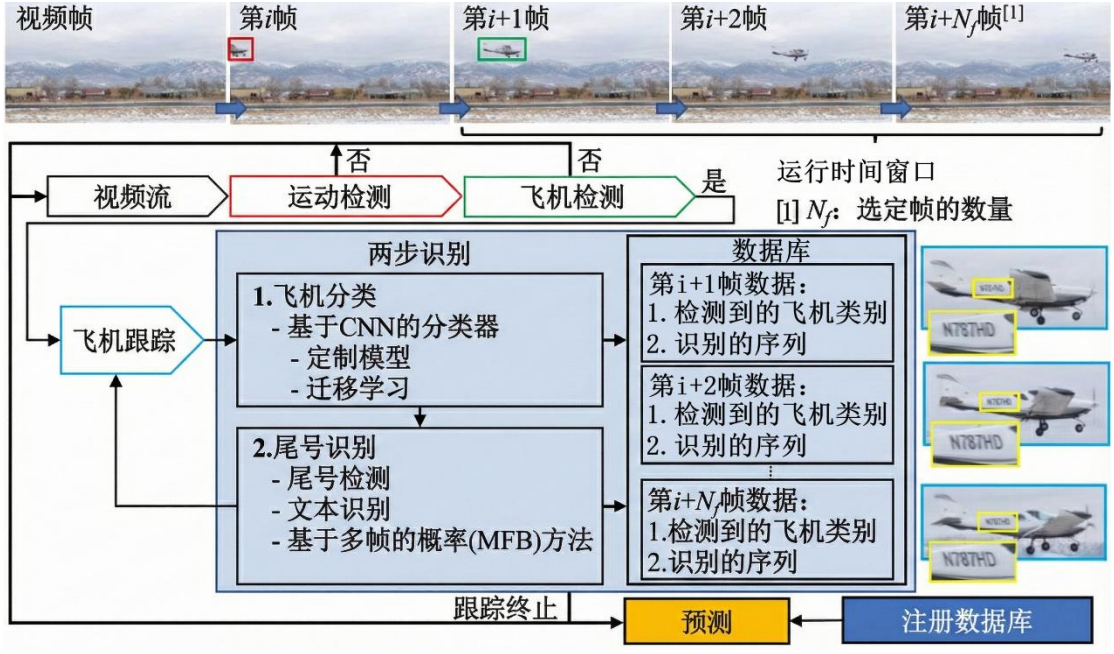


图 1.2 飞机识别系统流程图

1.1.3 图像复原：应对全天候感知的环境挑战

上述所有基于视觉的智能化应用，都面临一个共同的问题——环境退化。机场作为暴露在户外的关键设施，其监控系统采集的图像数据不可避免地受到恶劣天气和光照条件的影响，这些因素统称为退化（Degradation），常见退化包括：

- **恶劣天气**：浓雾导致能见度急剧下降，是诱发机场地面恶性交通事故与连环碰撞的主要隐患。雨、雪不仅会模糊镜头，跑道积水产生的复杂反射和散射更会导致感知系统失效，酿成无法挽回的惨剧。
- **恶劣光照**：夜间低照度环境下，目标主体大多隐匿于黑暗中。严重的光照不足导致飞机的姿态难以判定，机身尾号等关键细节无法辨识，使得有效视觉信息极度匮乏。

这些退化因素会严重阻断视觉信息的有效获取，导致管制员无法准确判断场面态势。美国联邦航空局（FAA）在研究中指出，基于视觉的 FOD 检测系统在低光照和恶劣天气条件下的性能会显著下降[6]。当管制员和 AI 算法依赖这些低质量、低信噪比的图像时，产生一个清晰的因果链：恶劣天气/光照使视觉传感器捕捉到退化图像，图像信息严重失真，导致下游 AI 算法（FOD 检测、目标跟踪）性能骤降[7]，从而导致管制员决策困难，机场容量降低，安全裕度下降[8]。

此外，机场作为一种特殊的光学环境，大气传输介质的不均匀性、极端的热力学条件以及复杂的气溶胶分布都会共同影响其退化机制。本项目中的图像恢复（IR, Image Restoration），即将被退化因素污染的图像恢复到清晰、高质量的状态——是消除上述连锁安全隐患的关键环节。本研究旨在为下一代全天候智能空管系统提供清晰、鲁棒的视觉感知基础，具有重大的行业应用价值和国家安全意义。



图 1.3 机场场面环境下多重退化因素的特征分析

1.2 国内外研究现状及发展动态分析

1.2.1 图像恢复的概念与分类

图像恢复是计算机视觉中的一个经典问题，旨在从退化观测中复原高质量清晰图像。常见的图像恢复任务主要包括去噪[9][10][11][12][13]、去雾[14][15][16][17][18]、去雪[19][20][21]、去雨[22][23][24]、去模糊[25][26]和低光增强[27][28][29]等。随着深度学习，特别是卷积神经网络（CNNs）[30]和 Transformer[31]的发展，图像恢复取得了巨大进展。

针对图像恢复问题的研究，前期主要集中于单退化恢复（SDIR, Single-Degradation Image Restoration），其针对特定的退化类型设计专属的网络架构和优化目标。尽管单退化恢复在各种类型的退化图像上取得 SOTA 表现，现存的单退化图像恢复方法仍普遍存在鲁棒性不佳、缺乏在未经二次训练的前提下对新退化类型的适应性的问题，同时，在面对复杂的真实场景时，往往存在多种退化的叠加，如果使用多退化恢复模型，系统需要先运行一个退化分类器来判断当前的退化类型，然后加载对应的单退化专用模型，如果分类器判断错误，后续的专用模型效果会大打折扣[32]。近年来提出的多合一图像恢复（AiOIR, All-in-One Image Restoration），旨在一个统一的框架内训练出无需二次训练即可对未知的新退化类型表现出良好适应性，且能用同一个模型处理单退化图像和多种退化叠加的图像的模型，可以弥补上述单退化图像恢复方法的不足。

1.2.2 多合一图像恢复兴起

多合一图像恢复代表了底层计算机视觉领域的一个重要范式转变：从针对特定退化训练专用模型，转向构建一个统一的、通用的框架，能够处理多种类型（如噪声、模糊、雨痕、雾霾等）及其混合的退化[33]。这一方向的兴起主要由计算效率的需求、深度学习架构的演进以及对通用图像先验的探索所驱动。

多合一图像恢复的发展大致经历了从简单的多任务学习到基于提示学习和动态网络的演进过程：早期的 AiOIR 方法通常采用多头或多编码器结构，使用一个共享的骨干网络提取通用特征，并在末端连接多个特定任务的“头”或“尾”来输出结果。然而，这种方法往往面临负迁移问题，即不同任务的优化目标可能在共享参数空间内产生冲突[34]，导致联合训练的效果反而劣于单任务训练。为了解决任务冲突，研究者引入了动态权重生成机制：网络根据输入图像的特性或指定的退化类型，自适应地调整卷积核权重或归一化参数[35]。例如，利用空间特征变换（SFT）层，根据退化类型调节中间特征图的仿射变换参数[36]。这

种方法允许网络在处理不同退化时激活不同的子结构或参数路径，从而缓解了任务间的干扰。为了在盲图像恢复设定下自动识别退化，研究者又引入了对比学习（如 AirNet[37]），在潜在空间（Latent Space）中拉近具有相同退化类型的图像特征，推远不同退化类型的特征，强制网络学习具有判别性的退化表示[38][39]，使得网络能够在没有人工标签的情况下，根据输入图像自身的统计特性自适应地选择恢复策略。

1.2.3 高质量配对数据集数量不足，模型习得表征能力受限

在多合一图像恢复的研究中，高质量配对数据集的稀缺以及由此导致的模型表征能力受限，是阻碍该领域向真实场景泛化的核心瓶颈。数据驱动的本质决定了深度学习模型的性能上限受数据集质量的制约。由于当下普遍缺乏复合退化数据集，模型在训练阶段从未见过多种退化叠加的样本，无法习得鲁棒的联合特征表示，导致模型无法正确处理真实世界中的复合退化任务，因此构建能够反映真实世界复合退化特征的数据集，是打破当前图像恢复技术瓶颈的重中之重。

多合一任务要求模型处理多种退化（如雨、雾、噪点、模糊），然而，构建大规模、多场景、多退化类型的高质量配对数据集，即严格对齐的退化图-清晰图对，在物理上极具挑战性。由于获取真实配对数据的高昂成本，现有主流数据集（如用于去雨的 Rain100[40]，用于去模糊的 GoPro[41]）多依赖于数学合成模型。例如，图像退化过程常被建模为简单的线性叠加：

$$y = kx + n$$

其中y是退化图像，x是清晰图像，k是模糊核，n是噪声。

然而，真实世界的退化往往是非线性的、信号依赖的，且涉及传感器特有的图像信号处理（ISP）管线变换。这种合成-真实域差异导致模型在合成数据上习得的表征无法有效迁移至真实数据。在数据规模方面，现有的多合一数据集通常规模较小（仅包含数千张图像），且场景内容单一[42]。这限制了数据分布的覆盖范围，当模型面对训练集中未出现的纹理或光照条件时，其潜在空间的插值能力会显著下降。数据量的不足直接制约了深度神经网络学习复杂映射关系的能力，具体表现为特征表示的混叠与语义信息的匮乏。

1.3 研究意义

1.3.1 突破多退化图像数据匮乏的瓶颈

在多合一图像恢复领域，一个重大的挑战在于难以获取真实的成对数据，即无法在现实机场中让场景在复合退化条件和无退化条件之间瞬间切换以获得像素级对齐的训练数据。现有的单退化数据集往往依赖简单的线性叠加合成，用于训练后，在真实场景的泛化性不佳。本项目利用 ScriptHookV 控制高保真仿真引擎（GTA V），构建工业级自动化数据生成管线，产出海量、逼真、严格像素级对齐的退化-清晰图像对，不仅实现了从 0 到 1 的突破，填补了 AiOIR 领域高质量复合退化数据集的空白，更从数据根基上打破了现有算法的性能上限，为下一代多合一图像恢复模型提供了不可或缺的决定性支撑。

1.3.2 突破视觉感知环境瓶颈，延伸空管系统的全天候运行边界

空管系统在恶劣天气、低光照等退化条件下高度依赖雷达，缺乏直观视觉信息。本项目致力于解决视觉传感器在复合退化条件下的失效问题，通过复合退化图像的多合一增强，使视觉监控系统在恶劣天气、低光照等退化条件下也能提供清晰的语义信息（如机身姿态、地面标识等），有效弥补雷达监视盲区，为空中交通管制员提供全天时的清晰态势感知支持。

1.3.3 引入基于物理先验的非线性合成，实现数据集真实感拟合

传统的退化图像合成方法通常假设退化是线性叠加的，然而，现实物理世界是非线性的，采用传统的线性合成方法会导致合成图像与真实世界中的图像存在特征差异，训练出的模型在真实世界中的泛化性不佳。通过 ReShade 后处理器和游戏引擎内部的物理渲染管线，本项目引入了真实的光学物理特性（如散射、折射、菲涅尔反射等），模拟了多种退化因素之间的耦合效应，这种基于物理渲染生成的图像更接近真实世界的监控画面，极大缩小合成图像与真实世界图像之间的特征差异，从而让训练出来的模型在先进场面活动引导与控制系统中具有更强的泛化能力。

参考文献

[1] 中国民用航空局. 2024 年民航行业发展统计公报[R/OL]. 2025. https://www.mot.gov.cn/fenxigongbao/hangyegongbao/202505/P020250825409204940412.pdf.

[2] International Civil Aviation Organization. Advanced Surface Movement Guidance and Control Systems (A-SMGCS) Manual[M]. 2004.

[3] Talbi A, Abdellaoui M, Pons-Prats J, et al. An Overview on Computer Vision Analysis in the Airport Applications[J]. IEEE Access, 2025, Volume 13: 120446-120471.
[4] Mo Yiming, Wang Lei, Hong Wenqing, et al. Small-Scale Foreign Object Debris Detection Using Deep Learning and Dual Light Modes[J]. Applied Sciences, 2024, 14(5): 2162.
[5] McCreary I. The economic cost of FOD to airlines[R/OL]. London:Insight SRI Ltd., 2008. https://fod-detection.com/wp-content/uploads/2009/12/the-economic-cost-of-fod.PDF.
[6] FAA Advisory Circular AC 150/5220-24: Foreign Object Debris Detection Equipment (2023), Section 3.2.
[7] Wang X, Liu X, Yang H, et al. Degradation modeling for restoration-enhanced object detection in adverse weather scenes[J]. IEEE Transactions on Intelligent Vehicles, 2024.
[8] Eurocontrol Experimental Centre. Human Performance Under Degraded Visual Conditions in Air Traffic Management, Technical Report No. EEC/SEE/2024/001 (2024).
[9] Dabov K, Foi A, Katkovnik V, et al. Color image denoising via sparse 3D collaborative filtering with grouping constraint in luminance-chrominance space[C]//2007 IEEE international conference on image processing. IEEE, 2007, 1: I-313-I-316.
[10] Liu J, Lin J, Li X, et al. Lira: Lifelong image restoration from unknown blended distortions[C]//European conference on computer vision. Cham: Springer International Publishing, 2020: 616-632.
[11] Tian C, Xu Y, Zuo W. Image denoising using deep CNN with batch renormalization[J]. Neural Networks, 2020, 121: 461-473.
[12] Zhang K, Zuo W, Chen Y, et al. Beyond a gaussian denoiser: Residual learning of deep cnn for image denoising[J]. IEEE transactions on image processing, 2017, 26(7): 3142-3155.
[13] Zhang K, Zuo W, Zhang L. FFDNet: Toward a fast and flexible solution for CNN-based image denoising[J]. IEEE Transactions on Image Processing, 2018, 27(9): 4608-4622.
[14] Cai B, Xu X, Jia K, et al. Dehazenet: An end-to-end system for single image haze removal[J]. IEEE transactions on image processing, 2016, 25(11): 5187-5198.
[15] Dong Y, Liu Y, Zhang H, et al. FD-GAN: Generative adversarial networks with fusion-discriminator for single image dehazing[C]//Proceedings of the AAAI conference on artificial intelligence. 2020, 34(07): 10729-10736.
[16] Fan X, Wang Y, Tang X, et al. Two-layer Gaussian process regression with example selection for image dehazing[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2016, 27(12): 2505-2517.
[17] He K, Sun J, Tang X. Single image haze removal using dark channel prior[J]. IEEE transactions on pattern analysis and machine intelligence, 2010, 33(12): 2341-2353.
[18] Li B, Gou Y, Gu S, et al. You only look yourself: Unsupervised and untrained single image dehazing neural network[J]. International Journal of Computer Vision, 2021, 129(5): 1754-1767.
[19] Chen W T, Fang H Y, Hsieh C L, et al. All snow removed: Single image desnowing algorithm using hierarchical dual-tree complex wavelet representation and contradict channel loss[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 4196-4205.
[20] Chen S, Ye T, Xue C, et al. Uncertainty-driven dynamic degradation perceiving and background modeling for efficient single image desnowing[C]//Proceedings of the 31st ACM international conference on multimedia. 2023: 4269-4280.

[21] Wang Y, Ma C, Liu J. Smartassign: Learning a smart knowledge assignment strategy for deraining and desnowing[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 3677-3686.

[22] Ren D, Zuo W, Hu Q, et al. Progressive image deraining networks: A better and simpler baseline[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2019: 3937-3946.

[23] Yang W, Tan R T, Wang S, et al. Single image deraining: From model-based to data-driven and beyond[J]. IEEE Transactions on pattern analysis and machine intelligence, 2020, 43(11): 4059-4077.

[24] Chen X, Li H, Li M, et al. Learning a sparse transformer network for effective image deraining[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023: 5896-5905.

[25] Tao X, Gao H, Shen X, et al. Scale-recurrent network for deep image deblurring[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 8174-8182.

[26] Yuan L, Sun J, Quan L, et al. Image deblurring with blurred/noisy image pairs[M]//ACM SIGGRAPH 2007 papers. 2007: 1-es.

[27] Guo X, Li Y, Ling H. LIME: Low-light image enhancement via illumination map estimation[J]. IEEE Transactions on image processing, 2016, 26(2): 982-993.

[28] Ma L, Ma T, Liu R, et al. Toward fast, flexible, and robust low-light image enhancement[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 5637-5646.

[29] Wang Y, Xie W, Liu H. Low-light image enhancement based on deep learning: a survey[J]. Optical Engineering, 2022, 61(4): 040901-040901.

[30] Krizhevsky A, Sutskever I, Hinton G E. ImageNet classification with deep convolutional neural networks[J]. Communications of the ACM, 2017, 60(6): 84-90.

[31] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.

[32] Jiang Y, Zhang Z, Xue T, et al. Autodir: Automatic all-in-one image restoration with latent diffusion[C]//European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2024: 340-359.

[33] Yang Z, Chen H, Qian Z, et al. All-in-one medical image restoration via task-adaptive routing[C]//International Conference on Medical Image Computing and Computer-Assisted Intervention. Cham: Springer Nature Switzerland, 2024: 67-77.

[34] Zamir A R, Sax A, Shen W, et al. Taskonomy: Disentangling task transfer learning[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 3712-3722.

[35] Chen Y, Dai X, Liu M, et al. Dynamic convolution: Attention over convolution kernels[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2020: 11030-11039.

[36] Wang X, Yu K, Wu S, et al. Esrgan: Enhanced super-resolution generative adversarial networks[C]//Proceedings of the European conference on computer vision (ECCV) workshops. 2018: 0-0.

[37] Li B, Liu X, Hu P, et al. All-in-one image restoration for unknown corruption[C]//Proceedings

of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 17452-17462.
[38] Zhang J, Huang J, Yao M, et al. Ingredient-oriented multi-degradation learning for image restoration[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2023: 5825-5835.
[39] Li Z, Lei Y, Ma C, et al. Prompt-in-prompt learning for universal image restoration[J]. arXiv preprint arXiv:2312.05038, 2023.
[40] Qian R, Tan R T, Yang W, et al. Attentive generative adversarial network for raindrop removal from a single image[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2018: 2482-2491.
[41] Nah S, Hyun Kim T, Mu Lee K. Deep multi-scale convolutional neural network for dynamic scene deblurring[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 3883-3891.
[42] Rim J, Lee H, Won J, et al. Real-world blur dataset for learning and benchmarking deblurring algorithms[C]//European conference on computer vision. Cham: Springer International Publishing, 2020: 184-201.

2．项目拟解决的关键科学问题，研究内容、总体框架、重点难点、主要目标（此部分为重点阐述内容）

2.1 总体研究框架

本项目遵循“数据构建—算法适配—性能评估”的研究路径，旨在建立首个全流程、物理精确的机场复杂环境场面监控图像专用复合退化恢复数据集，并验证其在提升空管视觉系统安全性方面的支撑能力。

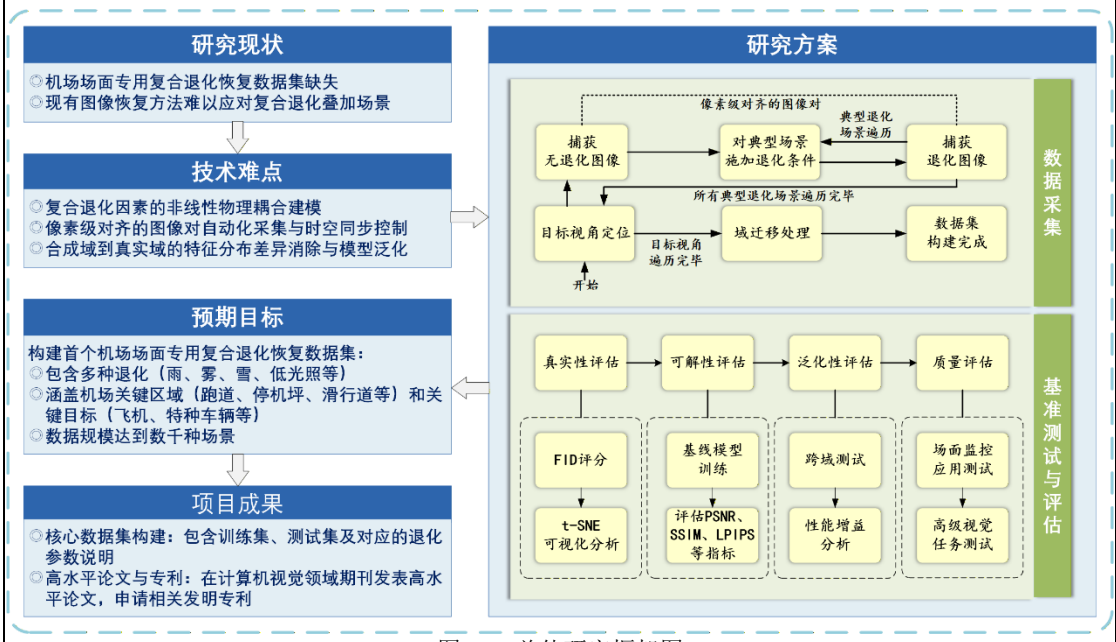


图 2.1 总体研究框架图

首先，在数据构建阶段，项目利用 GTA5 高保真仿真引擎 RAGE，通过 ScriptHookV 接口对天气、光照及渲染管线进行精细化调控，并引入 ReShade 后处理技术以模拟真实的光学物理特性（如散射、噪声）；采集流程中采用创新的“时间冻结”技术，在设置无退化环境捕捉参考图像后，保持场景几何状态绝对静止，遍历复合施加雨、雪、雾、低光照等多种非线性物理耦合的退化条件，生成严格像素级对齐的退化-清晰图像对。

在完成原始数据集构建后，进入关键的算法适配与域迁移阶段，针对合成数据与真实监控图像存在的域差异，本项目特别采用傅里叶域适应技术（FDA, Fourier Domain Adaptation），通过在频域上对齐源域（合成数据）与目标域（真实世界数据）的幅度谱信息，缩小风格与特征分布的差异，从而在保留语义内容的同时使合成图像数据更接近真实世界的数据分布特征，有效解决虚实迁移跨域泛化难题。

最后进入对数据集的多维度基准测试与评估阶段，该阶段细分为真实性评估、可解性评估、泛化性评估及质量评估四个板块：在真实性评估中，利用 FID 评分量化域适应图像和真

实世界图像的分布距离，通过 t-SNE 可视化分析特征分布重合度；在可解性评估中，选取 AirNet、PromptIR 等基线模型进行训练，计算 PSNR、SSIM 及 LPIPS 等感知指标；在泛化性评估中，重点开展跨域测试，验证使用本项目提出的数据集训练的模型在真实世界基准数据集中的表现及相对于其他合成数据集训练的模型的性能增益；同时进行质量评估，通过检查域适应处理前后的语义分割一致性来验证内容保留度，并测试模型输出的去退化图像在高级视觉任务中的表现，最终产出包含训练集、测试集及复合退化参数说明的 AiOIR 机场场面专用复合退化恢复数据集，为提升空管视觉系统的全天候鲁棒性提供坚实支撑。

2.2 主要研究内容

2.2.1 机场场面环境下多重退化因素的特征分析

在构建数据集之前，为了在虚拟引擎中进行精确的建模与复现，需要理解退化的本质，对机场环境下的光学退化机理进行初步的物理学剖析。

机场是一个复杂的光学环境，其退化机制是由大气传输介质的不均匀性、极端的热力学条件以及复杂的气溶胶分布共同作用的结果。为了在虚拟环境中精确建模，需要从以下三个物理维度进行分析：

- **热致折射率涨落**：即机场场面热浪。
- **介质散射与衰减**：场景反差被大气光冲淡，导致对比度降低；同时强光周围形成散射光晕，即发生光晕效应。
- **传感器成像链的非理想性**：机场场面监控通常涉及高动态范围场景，如在夜间漆黑背景下极亮的着陆灯，但机场场面监控由于设备性能限制，往往会导致高光溢出。在拍摄高速滑行或起降的飞机时还会产生运动模糊。

2.2.2 基于 ScriptHookV 与 ReShade 的高保真 AiOIR 数据集构建体系

此部分拟重点解决基于虚拟仿真引擎构建高保真、多退化机场场面监控数据集过程中的场景重构、物理仿真与数据对齐等核心难题。

1. 需要研究如何利用 ScriptHookV 劫持 RAGE 引擎，对机场特有的繁忙停机坪作业环境进行参数化重构，实现客机、地勤车辆及工作人员的批量实例化，同时屏蔽非相关背景干扰以保证数据纯净度。

2. 需要解决多重退化因素的精确调控与非线性耦合生成问题，包括如何编程控制降雨、风速及环境光照，以及如何利用 ReShade 后处理技术基于深度缓冲（Z-buffer）

模拟符合米氏散射理论的深度雾、雨水遮挡及光学散射光晕，从而突破传统线性叠加合成方法的物理不真实性。

3. 需要研究真实监控成像特征的模拟方法，涵盖高位俯视视角、广角畸变、自动曝光逻辑下的高光溢出或欠曝，以及传感器在低光照下的高斯、泊松噪声与信号传输伪影。

4. 需要解决动态场景下的像素级对齐难题，研究如何通过“时间冻结”技术在保持场景几何状态绝对静止的前提下切换退化条件，以自动化生成严格像素级对齐的退化-清晰图像对，消除时空不同步带来的训练误差。

2.2.3 合成数据集的真实性验证与域适应分析

此部分拟重点研究合成数据与真实机场场面监控图像在统计分布与视觉感知上的差异性验证问题，以及解决跨域特征迁移中的虚实迁移难题。



图 2.2 合成数据与真实机场场面监控图像在统计分布与视觉感知上的差异性

首先，需要研究建立一套客观的真实感量化评估体系，以克服传统主观视觉判断的局限性，通过探究合成数据与真实数据在特征空间中的分布距离及拓扑结构重合度，验证数据集在物理属性上的逼真程度。其次，将深入剖析 RAGE 引擎渲染图像与真实监控视频在纹理细节、光照风格及频域幅度谱上的本质差异，研究如何利用傅里叶变换等频域分析工具精准定位并消除这些导致模型泛化能力下降的分布偏差。此外，还需重点解决域适应过程中的内容一致性保持问题，即研究如何在将合成图像迁移至真实域风格的过程中，严格确保其原始的几何结构与语义信息不发生畸变，从而保证域适应处理前后的图像保持像素级精确对齐，验证数据集在实际空管任务中的有效性与可靠性。

2.2.4 面向空管任务的 AiOIR 算法基准测试与性能评估

此部分拟重点解决面向空管实际应用场景的 AiOIR 算法综合性能评估与数据集价值量化验证问题。首先，需要研究构建包含数据真实性与特征分布一致性的质量评估体系，旨在通过分析合成数据与真实监控图像在特征空间的分布距离，验证生成数据在物理属性上的保真度与多样性。其次，针对单纯依赖低层视觉指标无法全面反映空管业务需求的难题，本研究将致力于建立低层信号复原质量（如 PSNR、SSIM、LPIPS）与高层语义理解性能（如 FOD 异物检测精度 mAP、航空器识别率）相结合的多维度评价标准，深入剖析图像恢复质量对提升下游视觉任务的具体贡献机制。此外，还将重点研究模型在真实复杂场景下的跨域泛化能力评估问题，通过对比分析主流 SOTA 模型（如 AirNet、PromptIR）在复合退化条件下的性能边界，以及量化本数据集相对于现有开源合成数据集在真实世界基准测试中的性能增益，验证该数据集对增强全天候智能空管系统鲁棒性的实际应用价值。

2.3 重点难点

2.3.1 复合退化因素的非线性物理耦合建模

现有的合成方法多基于简单的图层叠加，例如将一张透明背景的雨点图通过滤色模式叠加到底图上。这种方法完全割裂了退化因素之间的物理联系。在真实世界中，雨滴会折射背后的霓虹灯，雾会散射灯光的光线形成光柱、光晕。如果忽略这些耦合，训练出的模型在遇到真实复杂光照时，会将这些光学效应误判为噪点或伪影，导致恢复结果失真。此外，传统合成退化通常是全图均匀叠加，缺乏深度信息，导致恢复出的图像景深错乱，影响管制员对飞机距离的判断。

2.3.2 动态场景下像素级对齐的图像对自动化采集

在捕获包含航空器滑行、地勤车辆移动等高动态场景时，构建严格像素级对齐的成对数据集面临巨大的时空一致性挑战。全监督图像恢复模型的训练依赖于退化-清晰图像对在几何结构上的绝对重合，然而，现有的仿真采集方法通常遵循“设置环境参数-渲染-切换环境参数-渲染”的串行逻辑。在设置环境参数并渲染的时间窗口内，机场场面中的动态目标会依照物理引擎的规律发生位移，导致不同退化条件下的图像对出现像素级错位。

这种微小的几何偏差在训练过程中会被神经网络错误地解释为高频纹理或边缘噪声，导致模型收敛困难甚至产生严重的伪影，极大损害模型的边缘保持能力。本项目的核心难点在于如何突破仿真引擎内部物理模拟与图形渲染的强耦合机制，即实现“物理时钟冻结”与“渲染管线刷新”的解耦，这要求通过底层 Hook 技术精确截获引擎的主循环帧，在强制停止所

有刚体动力学模拟和骨骼动画更新（即“时间冻结”）的状态下，依然能够独立驱动大气散射模型和粒子系统进行环境参数切换与画面重绘，从而确保在几何状态绝对静止的前提下，捕获多种典型复合退化场景的图像，实现动态场景下捕获多种复合退化图像时的严格像素级对齐。

2.3.3 合成域到真实域的特征分布差异消除与模型泛化

合成域到真实域的特征分布差异消除与模型泛化面临的核心难点在于，现有的合成数据生成方法往往难以完美复现真实世界复杂的物理成像过程，导致两者在特征分布上存在显著差异。传统的合成模型通常假设退化过程是简单的线性叠加，而真实机场环境中的图像退化往往是非线性的、信号依赖的，并且受到摄像机传感器特有的图像信号处理管线变换的深刻影响，这种物理机理上的本质区别使得合成图像在纹理、色彩分布及噪声特性上与真实监控图像存在难以逾越的鸿沟。这种分布不一致性会导致深度学习模型在合成数据上习得的特征表示无法有效迁移，当面对包含训练集中未出现的复杂纹理或光照条件的真实场景时，模型的潜在空间插值能力会显著下降，从而产生严重的负迁移现象或泛化失效，无法满足实际空管监控的高可靠性要求。

3. 【理工医科】**拟采取的研究方案及可行性分析**（包括研究方法、技术路线、实验手段、关键技术等说明）；【哲学社会学科】**思路方法**（本课题研究的基本思路、具体研究方法、研究计划及其可行性等）

3.1 研究方法与技术路线

3.1.1 利用 ScriptHookV 实现动态场景下像素级对齐的图像对自动化采集

为了重现图像退化条件之间的复杂非线性物理耦合特征，本研究基于仿真场景（GTA5），其底层的 RAGE 引擎具备世界顶级的渲染能力，设计了一套自动化数据采集流水线。RAGE 引擎的延迟渲染技术允许在场景中通过 G-Buffer（几何缓冲区）处理成百上千个动态光源，契合机场跑道光源密集的特点；该引擎还拥有体积光与天气系统，其内置的基于物理的天气系统，能够模拟云层厚度、降雨密度、风速对雨滴倾角的影响等细节，为各种退化类型非线性耦合的模拟提供极大便利。

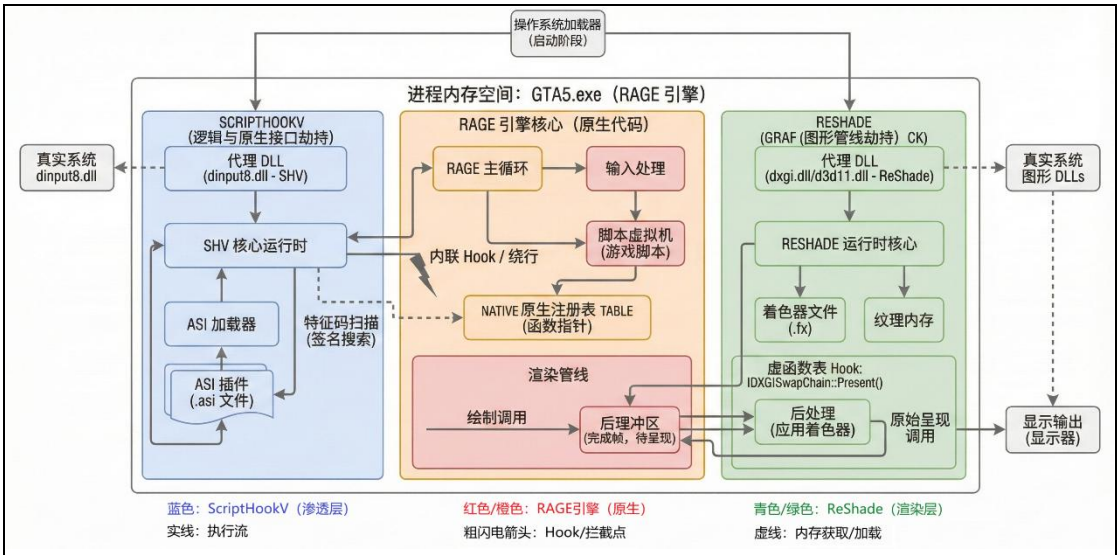


图 3.1 GTA5.exe 进程内存空间中，原生 RAGE 引擎代码与 ScriptHookV 及 ReShade 库的交互结构。左侧蓝色的 ScriptHookV 作为渗透层，通过代理 DLL 加载 ASI 插件，并利用特征码扫描和内联 Hook 技术接入 RAGE 引擎核心。中间橙色的 RAGE 引擎负责游戏主循环、脚本执行和基础渲染管线。右侧绿色的 ReShade 则通过 Hook 图形接口的呈现函数，在渲染完成后应用着色器进行后处理，最终输出到显示器。

ScriptHookV 是一个能够接管 RAGE 引擎主循环的程序库，允许通过编写 C++程序调用 RAGE 引擎内部的原生函数，它是实现可控、可量化、可叠加退化数据生成的核心，在本项目中主要承担复合退化场景参数化重构、退化因子调控及自动化采集流水线控制三大核心功能。

为了确保合成数据与真实应用场景的分布一致性，本项目利用 ScriptHookV 提供的原生函数接口，对游戏内的开放世界环境进行了针对性的改造与重构：项目成员编写 ASI 插件脚本，直接调用引擎对象池，在特定坐标通过代码批量实例化机场特有实体，包括客机、地勤牵引车及穿着特定制服的工作人员等，以模拟繁忙的停机坪作业环境。

本项目还利用 ScriptHookV 对渲染引擎内部状态的访问权限，实现了对环境光照及气象条件的精确控制，进而实现多重退化因子的精确调控与成对数据生成：本项目采用控制变量法，首先在标准光照的晴朗天气下采集无退化参考图像；随后，通过调用 ScriptHookV 提供的 GAMEPLAY::SET_TIME_SCALE 函数，在保持渲染引擎仍在工作的前提下停止物理模拟，在保持摄像机位姿与场景物体几何状态绝对静止的前提下，脚本自动修改气象参数以模拟恶劣天气、修改时间参数以模拟低光照度，进而采集对应的复合退化图像。该方法保证了无退化参考图像与复合退化图像在像素层面的一一对应，为 AiOIR 模型提供了高质量的训练样本。为了缩小合成数据与真实监控数据在成像几何特征上的差异，项目还通过脚本接管了渲染视口控制权：在插件脚本中调用原生函数构建虚拟摄像机，锁定其三维坐标于高处，并固定俯仰角与偏航角，模拟真实监控探头的高位俯视视角，同时调整虚拟摄像机的焦距与

视场角参数，使其符合广角监控镜头的成像畸变特征，并去除所有用户界面元素，输出纯净的视频流截图。

3.1.2 基于 ReShade 后处理器的非线性合成

尽管 RAGE 引擎原生画质优秀，但为了追求极致的物理准确性，研究引入了 ReShade 后处理注入器，实现微观成像质量控制与复杂光学退化模拟。真实机场监控摄像机，尤其是老旧或低成本设备，在弱光或高温环境下会产生显著的噪声，本项目通过 ReShade 加载基于统计模型的噪声着色器，模拟真实 CMOS/CCD 传感器在高 ISO 增益下产生的高斯噪声与泊松噪声，以及夜间监控特有的椒盐噪声。针对模拟信号监控设备，本项目通过 ReShade 应用扫描线干扰和色度串扰滤镜，重现真实监控画面中常见的信号衰减与传输伪影特征。

虽然 RAGE 引擎自带基础的天气效果，但难以满足深度学习模型对极端恶劣天气恢复能力的训练需求。为解决传统合成方法缺乏对深度信息的利用的问题，本研究利用基于深度缓冲（Z-buffer）的体积渲染技术，ReShade 通过访问深度缓冲区，实现基于物理的视觉增强：使用 ReShade 读取 RAGE 引擎渲染管线中的线性深度值z，依据公式$I = Je^{-\beta z} + A(1 - e^{-\beta z})$，对每一个像素点独立计算雾的浓度，根据物体距离摄像机的远近，非线性地增加雾霾浓度，精确模拟大雾天气下的能见度衰减规律。这种基于几何深度的合成，迫使神经网络学习到深度线索，从而更准确地估计透射率图。本项目还利用 ReShader 的 Bloom 着色器模拟光线在雨雾介质中的散射，当检测到像素亮度超过阈值（即光源）时，算法会根据当前天气的浑浊度参数，向周围像素扩散亮度，生成符合物理规律的光晕。这使得模型能够学习区分有用的信号灯和有害的散射光。

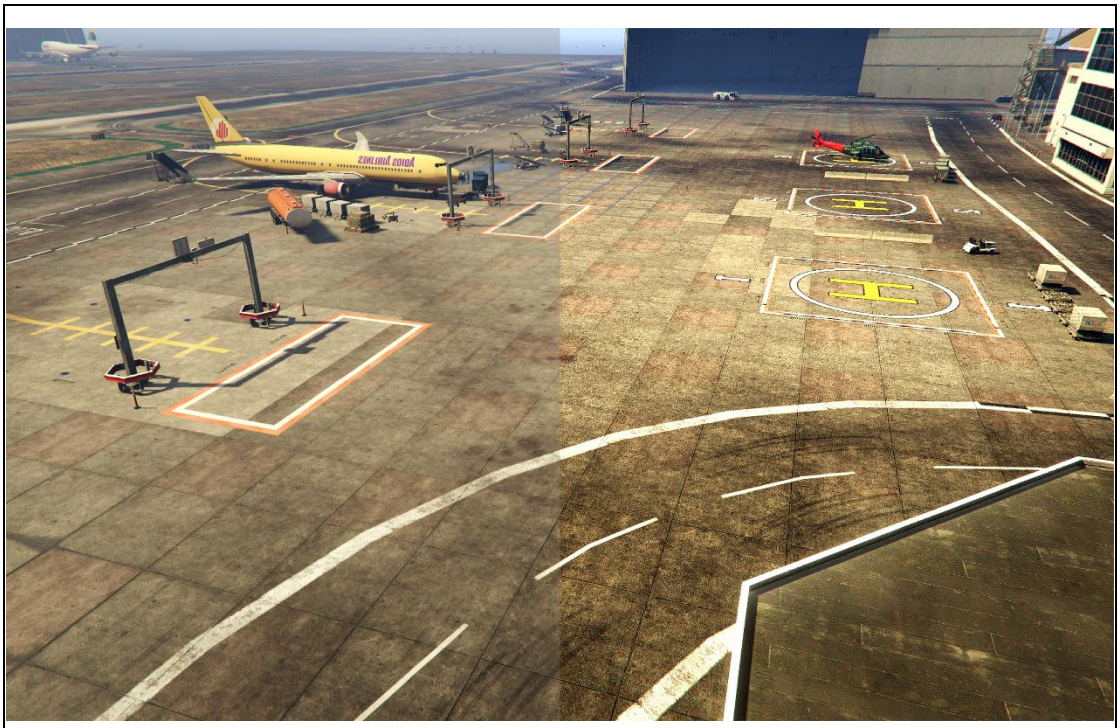


图 3.2 ReShade 优化前（左半部分）和优化后（右半部分）

为了使合成图像的色彩空间分布更接近真实的安防监控视频，本项目还利用 ReShade 接管了最终的色彩后处理管线：编写或调用特定的 LUT（Look-Up Table）文件，将游戏引擎原本鲜艳、高动态范围的渲染风格，强制映射为监控摄像头特有的低对比度、低饱和度及特定白平衡偏移的视觉风格。本项目还模拟了监控摄像头的自动曝光逻辑，在面对机场强光（如探照灯直射）时产生过曝光晕，或在背光区产生欠曝，迫使 AiOIR 模型学习处理局部光照不均的复杂场景。ReShade 提供了高度模块化的着色器管理机制，允许用户灵活地对不同视觉特效进行独立配置与管线编排。该机制支持将模糊、噪声、天气干扰等多种退化算子进行层级化叠加，从而能够高效地模拟真实世界中多因素耦合的恶劣环境，便于构建分布广泛且具有高拟真度的复合退化样本。

针对合成数据与真实机场场面监控图像在纹理、光照及噪声分布上存在的显著域差异导致模型泛化能力下降的问题，本项目拟采用傅里叶域适应技术来实现高效的虚实迁移与特征对齐。

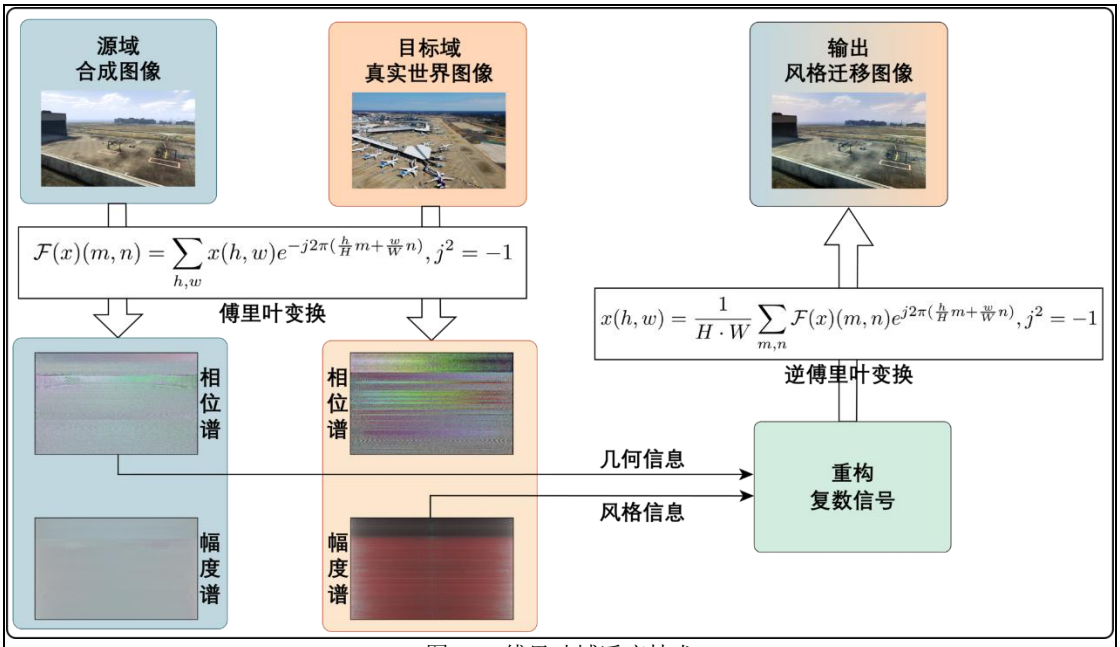


图 3.3 傅里叶域适应技术

该技术利用频域属性的解耦特性，即图像的幅度谱主要编码了光照、色彩和纹理等低层风格统计信息，而相位谱则承载了物体边缘与几何结构等高层语义内容。研究将通过傅里叶变换将源域的 RAGE 引擎合成图像与目标域的真实机场场面监控图像映射至频域空间，在严格保持合成图像相位谱不变以确保语义标签（如飞机位置、轮廓）精确对应的基础上，将其低频部分的幅度谱替换为目标域真实世界图像的幅度谱分量，随后利用逆傅里叶变换重构出兼具真实监控视觉风格与像素级精确对齐的训练样本。这种无需额外参数学习的频谱级对齐策略，能够直接在输入端消除合成图像的虚假感，迫使模型在训练阶段就适应真实世界的特征分布，从而在不增加真实数据标注成本的前提下，显著提升图像恢复模型在实际机场场面监控任务中的鲁棒性与泛化表现。

3.1.3 基线模型测试与数据集性能评估

为了全面且严谨地评判本项目构建的基于 GTA5 与傅里叶域适应（FDA）的多合一图像恢复数据集质量，拟建立一套涵盖分布真实感、模型基准表现、虚实迁移泛化能力及内容一致性的多维评估体系。

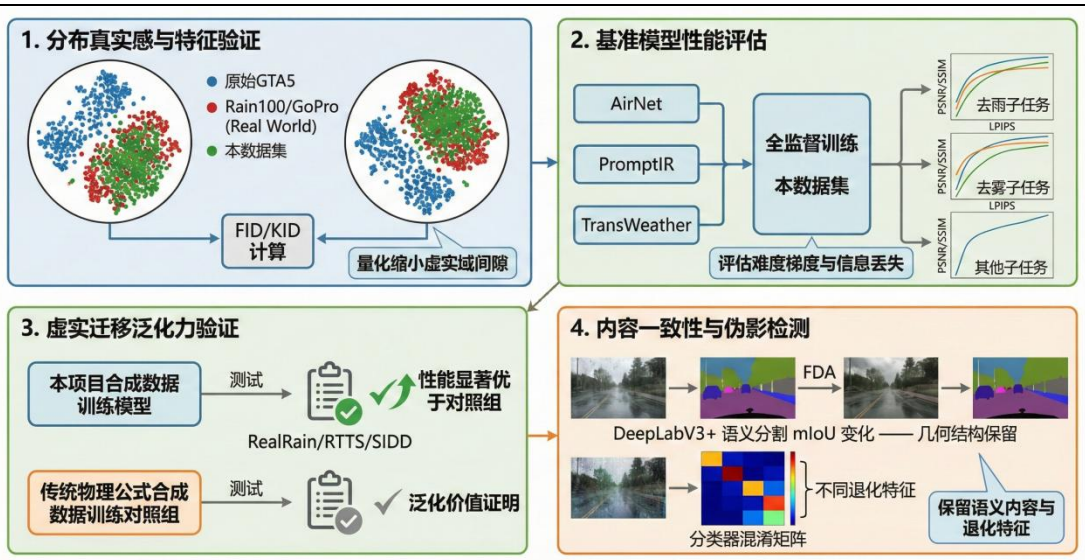


图 3.4 GTA5+傅里叶域适应多合一图像恢复数据集的多维评估体系

首先，针对数据分布与真实感验证，研究将计算 FID 与 KID 感知指标并结合 t-SNE 特征降维可视化分析，定量对比本数据集与 Rain100、GoPro 等真实世界数据集以及原始 GTA5 数据之间的特征分布距离，以此科学量化傅里叶域适应操作在缩小虚拟与真实域差异方面的实际效能。其次，在基准模型性能评估环节，将选取 AirNet、PromptIR 及 TransWeather 等主流多合一 SOTA 模型在本数据集上进行全监督训练，通过监测 PSNR、SSIM 及 LPIPS 等指标在去雨、去雾等不同子任务下的收敛轨迹与数值差异，评估数据集的难度梯度是否合理以及是否存在导致信息丢失的破坏性退化。更进一步，项目将执行关键的虚实迁移验证，即完全依赖本项目的合成数据训练模型，随后直接在 RealRain、RTTS 或 SIDD 等权威真实世界基准数据集上进行测试，若其性能显著优于使用传统物理公式合成数据训练的对照组，将强有力地证明本数据集在真实场景下的泛化价值。最后，为了确保域迁移过程的安全性，将开展内容一致性与伪影检测，利用 DeepLabV3+模型计算 FDA 处理前后图像的语义分割 mIoU 变化以验证几何结构保留度，并通过分类器构建混淆矩阵检测不同退化特征的独立性，确保在提升视觉风格真实感的同时，严格保留原始图像的语义内容与退化类别特征。

3.2 可行性分析

3.2.1 理论与技术路线成熟可行

本项目采用的“虚拟引擎合成、域适应迁移、基线模型测试与评估”技术路线在计算机视觉领域已有成熟的理论支撑。RAGE 引擎因其极高的渲染逼真度和完善的物理引擎，已被广泛应用于自动驾驶（如 PreSIL 数据集）和场景理解研究中。本项目利用 ScriptHookV 接口和 ReShade 后处理技术，能够精确控制天气、光照及摄像机参数，这种基于物理渲染和大气散射模型的非线性合成方法，在理论上完全能够模拟出符合物理定律的雨雾光学特征，技

术路径清晰明确，且项目成员已编写出可运行的自动数据采集程序。



图 3.5 数据自动采集程序输出的部分数据

此外，本项目拟采用的傅里叶域适应方法是解决虚实迁移鸿沟的经典且高效手段，数学原理完备。同时，AirNet、PromptIR 等基准 AiOIR 模型均已有开源代码和预训练权重，为本项目的算法测试与评估提供了坚实的对比基础。

3.2.2 项目团队具备扎实的学科基础与工程能力

项目核心成员来自四川大学计算机学院（软件学院、智能科技学院）、吴玉章学院的计算机科学与技术拔尖计划试验班，具备极强的数理基础和编程实践能力。团队成员　　曾获得 2025 年 ICPC 国际大学生程序设计竞赛亚洲区域赛（西安）金奖、全国邀请赛金奖以及蓝桥杯全国总决赛一等奖，第 36 届 CSP 认证获满分，证明团队具备卓越的代码实现能力和复杂算法解决能力，能够胜任 ScriptHookV 插件开发（C++）及深度学习模型调试（Python/PyTorch）等复杂工程任务。项目负责人　　及其他成员在本科阶段已接受系统的计算机视觉与人工智能课程训练，熟练掌握深度学习框架及图像处理流程，能够快速消化相关文献并转化为实际代码。

3.2.3 指导教师与实验平台提供强力支撑

本项目依托国家空管自动化系统技术重点实验室、现代交通管理系统教育部工程研究中心及四川大学“智能空管”工科特色团队。实验室拥有全业务流程的空管自动化系统和多通道数字记录仪，能够提供大量真实的机场监控视频作为目标域数据，这是构建高保真数据集的关键。同时，实验室配备的深度学习计算中心拥有充足的 GPU 算力资源，完全满足本项目大规模图像渲染与模型训练的硬件需求。指导教师　　是智能空管领域的专家，主

持多项国家自然科学基金项目，并在 Nature Communications、IEEE 汇刊等发表多篇高水平论文，拥有深厚的空管态势感知技术积累。指导教师在空管数据理解与多模态融合方面的经验，能准确把控本项目的研究方向，确保研究顺利开展。

4. 本项目的特色与创新点（建议 2-3 点）；

1. 构建首个面向机场场面监控的 AiOIR 数据集，填补研究空白。

2. 提出基于傅里叶变换的域适应方法，突破合成数据虚实迁移瓶颈。

3. 建立“信号复原-语义感知-跨域泛化”多维基准评估体系，量化数据应用价值。

（二）研究基础与工作条件

1. 项目负责人研究基础（建议 300 字以内）