（交叉学科子计划项目需填写第二指导老师）			
姓名	所在学院或单位	研究方向	职称/职务
性别/年龄	手机	电子邮箱	签名

项目摘要(限 200 字以内)

针对现有 3D 生成模型在解剖一致性与多视角稳定性上存在结构幻觉和 Janus 伪影、难以达到临床精度的痛点,本项目提出一种基于显式解剖先验纠正生成式流形分布的混合生成方法。拟构建以 SMAL 生物骨架为刚性解剖先验，融合最优传输流匹配（OT-CFM）与高斯磨砂（Gaussian Frosting）的混合生成架构，开展面向合成到真实（Sim-to-Real）的跨域三维重建研究。项目面向宠物医疗开发低成本、无创体态分析与术前虚拟备皮系统，缓解对 CT 依赖，完善数字化医患沟通与院外康复监测。

特色创新点（限 100 字以内，建议 2-3 点）

1. SMAL 骨架先验嵌入流网络+Gaussian Frosting 防畸变 3D 生成。
2. OT-CFM 在极少预算下生成高保真细节。
3. 构建兽医三维影像交互视诊系统。

报告正文

（一）立项依据与研究内容（建议 8000 字以下（不包括文献））

1. 项目的立项依据

1.1 项目研究意义

本项目以“骨影生形：面向宠物医疗的解剖约束三维智能重建系统”为题，旨在聚焦当前宠物医疗服务场景中三维可视化能力普遍不足的问题，探索一种基于单目图像输入的低成本三维外观建模方法，构建轻量化、可交互的个体化宠物三维模型，以提升医患沟通效率、支持体态管理与康复随访、赋能教学科普与数字服务延伸。项目不以替代专业影像设备或直接诊断为目标，而是面向服务过程中的“可视化表达”与“空间认知”，填补当前宠物医疗服务流程中可视化工具链的空白，推动“AI+医疗健康”战略在宠物健康领域的技术延伸与场景落地。

1.1.1 国家战略导向与宠物医疗服务升级需求

在国家政策层面，《新一代人工智能发展规划》[1]《健康中国 2030 规划纲要》[2]等文件多次强调，要推动人工智能与医疗健康领域深度融合，构建智能化、可视化、精准化的服务体系，以满足人民群众日益增长的健康与关怀需求。在“数字中国”战略和医疗服务下沉趋势共同推动下，医疗技术的发展正从聚焦“诊断与治疗”逐步向“沟通、管理、教育、人文关怀”等多维度服务环节延伸。

宠物作为家庭结构与情感关系中的重要成员，宠物医疗的服务品质已成为“它经济”向“它健康”演化的关键指标。据毕马威《2025 年中国宠物行业市场报告》[3]测算，我国宠物相关业务市场规模已由 2015 年的 978 亿元快速增长至 2023 年的 5,928 亿元，2015—2023 年年均复合增长率达 25.4%，预计 2025 年有望突破 8,114 亿元。其中，宠物医疗支出占比持续提升，呈现出从“治得起”向“治得好、治得安心”的结构性升级趋势。与此同时，以 90 后、00 后为代表的年轻一代养宠群体日益成为主力消费人群，他们普遍具备较强的信息素养和数字化使用习惯，尤其重视医疗过程中的信息透明度、沟通体验与心理陪护，亟需更具可视化表达力与人性化设计的数字医疗工具作为支撑。

在此背景下，宠物医疗服务机构亟需补齐“三维可视化”能力短板，发展具备医学语义一致性、个体外观相似性、服务交互友好性的轻量级三维展示系统，既满足临床沟通和康复记录等现实需求，又契合政策导向和产业升级的技术要求。

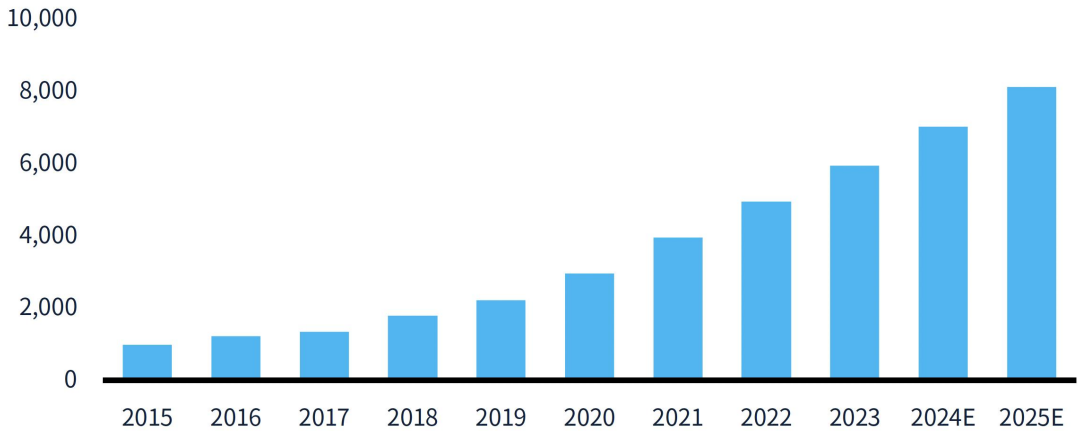


图 1 中国宠物相关业务市场规模及增长趋势（2015－2025 年）[3]

1.1.2 宠物医疗场景中的三维可视化能力缺口

尽管宠物医疗对可视化表达的需求日益增长，现实服务流程中仍普遍缺乏高效、可信、易用的三维可视化工具。在实际就诊与沟通环节中，医生主要依赖二维图像、手绘草图和口头讲解来向宠物家属解释诊疗方案。对于缺乏医学背景的非专业用户而言，这种信息表达形式往往难以准确理解空间位置、手术区域范围以及术后体态变化等关键问题，影响沟通效率与治疗配合程度。

与此同时，当前通用三维建模方法多面向娱乐、内容生产等非医疗场景，缺乏解剖结构约束与姿态合理性保障。在动物外观复杂、姿态多样、毛发遮挡显著的条件下，易出现“结构幻觉”“Janus 伪影”等伪造效果，导致骨骼穿插、关节越界、体态比例失真等问题，严重制约其在专业场景下的可用性和可信度。

综上，宠物医疗场景面临以下三维可视化能力空缺：

- 缺乏结构可信、可交互的三维表达载体，限制医患间对诊疗区域的空间认知；
- 缺乏基于解剖语义的一体化建模机制，难以用于术后体态恢复、康复趋势可视化展示；
- 缺乏面向教学科普与服务延伸的数字建模工具，无法支撑三维病例展示、健康宣教与人文关怀等应用需求。

因此，如何以低成本方式构建结构一致、形态可信、适用于医疗服务场景的三维可视化工具，已成为宠物医疗服务链条中亟待解决的重要课题。

1.1.3 拟解决的关键问题与“骨影生形”技术路径定位

本项目旨在解决以下核心问题：

在单张或少量宠物图像输入条件下，如何实现结构解剖一致、个体特征相似、可视化展示友好的三维外观重建系统，并使其适配于医疗场景中的沟通解释、康复管理与科普教学，而非承担直接诊断功能。

为此，项目设计了具备显式解剖建模与生成细化能力的三阶融合技术架构，即“AniMer+几何重建[4] → 基于最优传输的条件流匹配（OT-CFM，一种改进的 Rectified Flow 框架）流形桥接细化[5] → Gaussian Frosting 混合渲染[6]”。

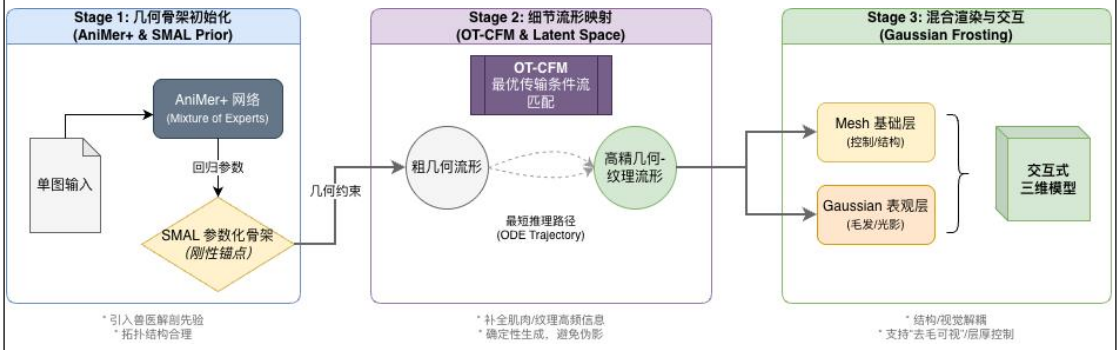


图 2 “骨影生形”三阶段技术架构总览示意图

首先，基于单图图像输入，通过融合家族专家机制（Mixture of Experts）的 AniMer+ 网络回归 SMAL 参数模型，构建拓扑结构合理、关节连接真实的四足动物几何骨架。该阶段以 SMAL 参数化骨架为刚性锚点，将兽医解剖先验显式引入网络，确保生成结果在四肢数量、关节拓扑等方面具备良好的解剖一致性，为后续细节表达奠定结构基础[4]。

其次，引入基于最优传输的条件流匹配（OT-CFM）算法，在显式几何骨架约束下，将“粗几何流形”上映射得到的潜在表示，连续地输运至“高精几何－纹理流形”上的精细表示，构建从素模到高保真细节的确定性数据－对－数据最短推理路径。该阶段不仅对几何姿态进行细化，还在潜空间内补全肌肉轮廓、局部形体与体表纹理等高频信息，有效避免常规随机扩散方法中易产生的伪影与结构错配现象。

最后，采用 Gaussian Frosting 混合渲染方法，在保持可编辑网格骨架的前提下，通过高斯原语对体表软组织与毛发表观进行体积化建模，将结构建模与视觉渲染路径解耦：网格负责解剖结构与动画控制，高斯层负责毛发、皮肤高光、光照交互等细节的高保真呈现[6]。依托 Frosting 的层厚控制与模糊度映射，本系统可在毛发、皮肤与近表组织之间灵活切换，实现“去毛可视”“局部放大”等面向临床沟通与教学的交互视效。

综上，本项目所构建的系统并不替代现有医疗成像与诊断工具，而是以结构清晰、形态真实、表达直观的三维外观模型为核心，为宠物医疗服务中的医患沟通、病程记录、康复管理与科普教育提供可信的三维可视化支撑。

1.1.4 应用场景与预期效益

围绕上述架构，本项目所开发的三维可视化系统将有效嵌入宠物医疗服务流程中的多个关键环节，预期产生如下应用价值与社会效益：

首先，在医疗服务环节，系统可用于辅助医生向宠物家属清晰解释手术区域、影响范围及空间关系，通过个体化三维模型进行交互式标注与可视化演示，弥补二维图像在空间表达上的局限性，显著提升医患沟通效率与信任水平。同时，在远程问诊与初步分诊场景中，医生与家属可围绕统一模型进行空间位置标注，减少沟通歧义，提升服务体验。

其次，在康复管理与长期随访环节，系统支持对不同时点采集图像生成的三维模型进行体态对比与趋势观察。对于骨科手术后站立姿态变化、体型轮廓调整、负重平衡恢复等方面的可视化记录，能够辅助医生制定康复方案，也便于家属理解宠物恢复进展，提高健康管理的参与感与科学性。

第三，在辅具适配与穿戴规划方面，基于三维外观模型提供的几何参数与体型轮廓，可为防舔圈、背带、护具等外部设备选择与设计提供初步参考，减少试戴次数与不适配风险，

提升使用舒适度与治疗配合度。

最后，在教学、科普与人文服务方面，系统可作为兽医教学平台与宠物医疗机构的三维案例资源，用于临床教学、健康宣教及服务品牌构建。通过生成结构合理的“数字宠物分身”，实现康复动画展示、情绪陪护模拟等人文功能，增强宠物家属的信任感与情感联结，推动宠物医疗服务体系由“技术导向”向“人文温度”拓展。

综上所述，本项目以构建轻量化、可信赖、可交互的宠物三维外观建模系统为目标，不承担直接诊断功能，而致力于拓展宠物医疗服务中三维可视化的深度与广度，赋能服务流程的数字化转型与价值提升，具有显著的现实意义与推广前景。

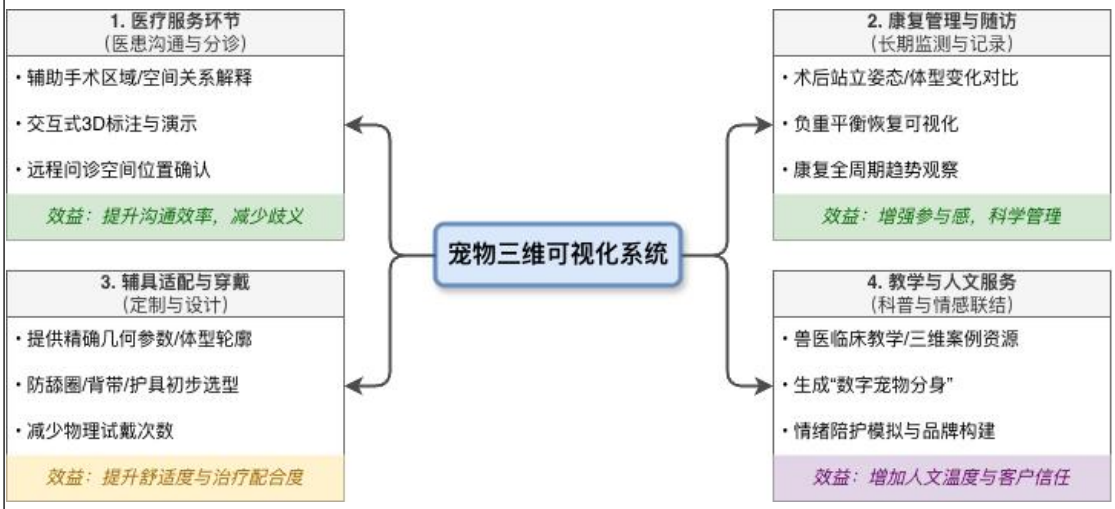


图 3 本项目三维可视化系统在医疗、康复、辅具与教学场景中的应用

1.2 国内外研究现状及发展动态

近年来，三维动物建模技术在几何主干重建、生成式外观细化与真实感渲染等方面持续演进，逐步形成了一条融合结构建模、生成机制与视觉表现的复合式技术路径。当前国内外研究主要聚焦于以下三个关键方向：

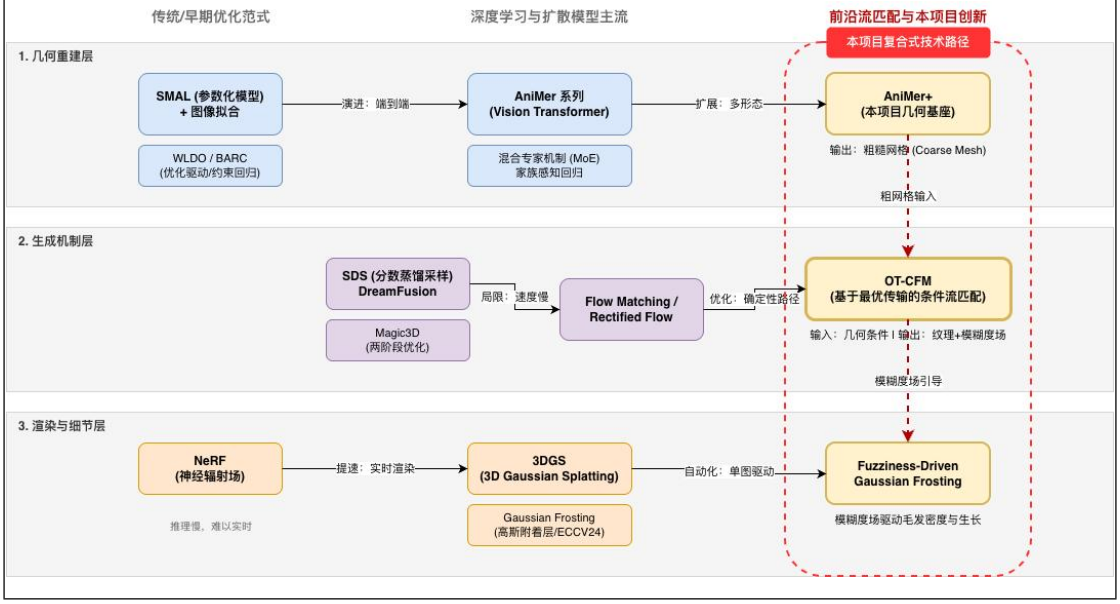


图 4 三维动物建模关键技术演进路径与本项目技术架构对比

1.2.1 基于解剖模型的三维几何重建：从传统拟合到家族感知的深度回归

当前三维动物重建仍以参数化模型+图像拟合为基本范式。SMAL（Skinned Multi-Animal Linear model）作为一种广泛使用的结构化模型，为建模多种哺乳动物提供了统一的骨架表示框架[7]。早期方法主要采用优化驱动的策略，通过图像关键点与模型轮廓之间的迭代匹配实现几何拟合。例如，Biggs 等人提出的 WLDO 方法采用期望最大化策略对 SMAL 模型进行逐步配准，从单张犬类图像中重建骨架形态[8]。Ruegg 等人提出的 BARC 则在训练过程中引入犬种分类与三元组约束，提高了模型的判别能力与回归精度[9]。尽管此类方法在特定品种范围内表现良好，但普遍存在对初始关键点依赖度高、推理效率低、易陷入局部最优的问题，难以满足通用化与实时性的实际需求。

针对这些局限，近年来基于深度学习的端到端重建方法成为主流。AniMer 系列方法是该方向的重要代表，其核心创新在于引入 Vision Transformer 结构并结合混合专家（Mixture-of-Experts）机制，建立了“家族感知”的通用回归框架[10]。该模型将不同动物类群（如猫科、犬科）分别映射至特定的子网络模块，并通过动态路由机制调度专家分支，在共享参数的同时保留物种特征差异，从而有效提升跨物种建模的一致性与表达能力。2025 年提出的 AniMer+ 更进一步，将重建范围扩展至鸟类等多形态物种，并在多个数据集上刷新重建精度[4]。尽管此类方法在“几何骨架”层面已具备较强表达能力，但其输出形态仍为光滑的裸露网格，缺乏表面纹理与细节建模，难以满足视觉真实感与临床辅助展示等多层次需求。

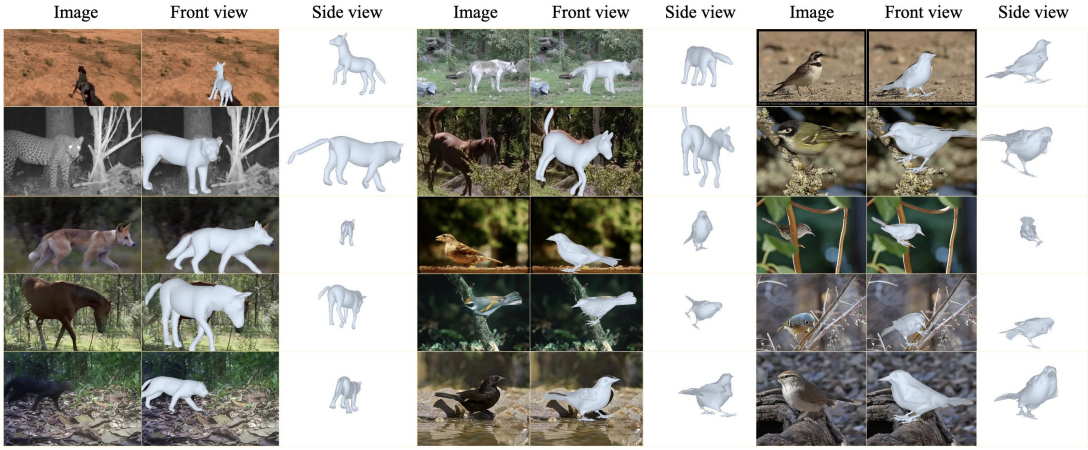


图 5 AniMer+ 在 Animal Kingdom[11] 与 CUB[12] 数据集上的定性结果示例。[4]

1.2.2 生成式纹理建模方法的发展：从随机扩散到确定性条件流匹配

为弥补几何结构的细节缺失，近年来研究者将生成模型引入三维纹理与材质生成任务，尤其以基于 Score Distillation Sampling（SDS）的优化范式为代表[13]。以 DreamFusion 为起点，该方法借助预训练的图像-文本扩散模型引导 NeRF 表示学习，从而实现与文本描述或图像条件相匹配的三维内容生成。后续 Magic3D 等工作在此基础上引入两阶段生成机制，通过 NeRF 到网格的粗细化建模显著提升了输出质量与空间一致性[14]。尽管 SDS 技术使得三维模型具备了外观表达能力，但仍存在诸多局限，主要包括采样效率低、训练耗时长、生成结果在多视角下存在结构歧义（即 Janus 多面体问题），以及高频细节表现力不足等问题。

在此背景下，生成模型逐渐从随机扩散演化为更高效、可控的流匹配（Flow Matching）与整流流（Rectified Flow）框架。Flow Matching 方法通过直接回归噪声分布到目标分布

之间的最优流场，在训练阶段构建连续时间的生成路径[15]。基于最优传输理论，Rectified Flow 更进一步简化了采样过程，将扩散过程压缩为一条近似笔直的 ODE 路径，有效减少了采样步数，并提高了样本质量与稳定性[5]。该类方法凭借其确定性与结构一致性，已在图像生成领域表现出优于传统扩散模型的性能潜力。

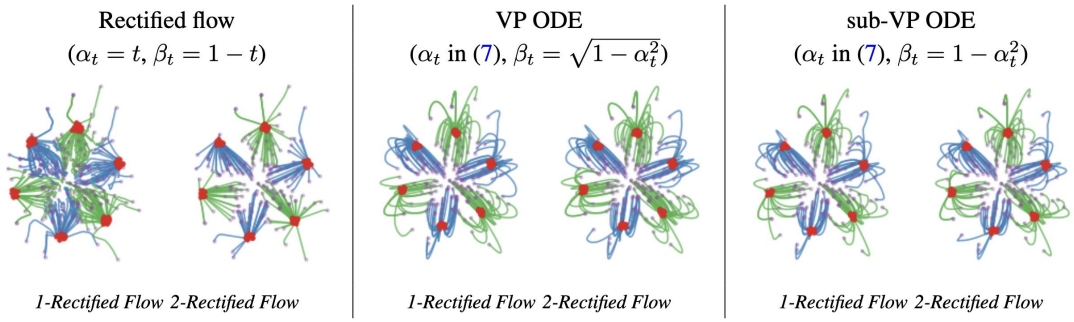


图 6 基于流匹配的直线生成路径与传统扩散曲线路径的对比示意图[5]

本项目结合上述思路，提出基于最优传输的条件流匹配（OT-CFM）机制，创新性地将几何结构生成与纹理表达过程统一于条件流建模框架。该方法以 AniMer+ 输出的粗网格为起点，通过条件流网络直接生成包含细化几何、纹理特征图与模糊度分布的复合特征场，在保证结构一致性的同时高效补充毛发区域信息，从而实现“从粗到细”的一体化生成流程，有效规避了扩散模型的高代价优化与不稳定性问题。

1.2.3 神经渲染与毛发细节建模：从 NeRF 向可实时渲染的高斯表示发展

在渲染表现层面，NeRF 曾作为新视角合成的主流方案广泛应用于三维重建任务，但其推理效率瓶颈限制了实际部署[16]。2023 年，Kerbl 等人提出的 3D Gaussian Splatting（3DGS）方法通过引入空间各向异性高斯表示与可微分渲染优化，有效兼顾了训练速度与渲染帧率，在保持 NeRF 精度的同时支持高分辨率下的实时交互显示[17]。该方法已被广泛认为是神经辐射场在效率与表现力之间取得平衡的关键技术，具备良好的可扩展性。

然而，针对动物毛发等复杂体积细节，传统 NeRF 或 3DGS 难以显式建模材质的蓬松结构。为此，Guédon 和 Lepetit 等人于 ECCV 2024 提出了 Gaussian Frosting 方法[18]，采用“高斯附着层”模拟毛发或草丛等细密结构，将可动画驱动的网格模型与体积渲染机制融合，从而实现在任意视角下对毛发覆盖、遮挡与材质厚度的真实表达。该方法在多视图输入场景下表现良好，但在单图像输入下面临毛发区域定位困难、掩膜依赖强等实际挑战，尚难以作为自动化系统的直接构件使用。



(a) Rendering **(b)** Thickness of the Frosting layer

图 7 Gaussian Frosting 自适应附着层厚度可视化示意图[18]

本项目在此基础上构建了完整的细节建模闭环：通过 OT-CFM 模块一并输出几何细化结果与模糊度场（fuzziness field），将其作为毛发表达的先验引导信息，驱动 Gaussian Frosting 在高模糊区域自动生成更密集的高斯层，在低模糊区域保持光滑结构。该机制打通了从几何建模、特征生成到细节渲染的完整流程，实现了在单图条件下的三维毛发自动生成，有效弥补了现有方法在表观层次的表达能力缺口。

小结：

总体来看，近五年来三维动物建模研究逐步形成了以“结构建模 - 条件生成 - 材质表达”为核心的多层次协同架构。在几何层面，从优化拟合向解剖感知的深度回归演进；在生成机制上，从随机扩散向确定性流匹配（包括基于最优传输的条件流匹配 OT-CFM）演进；在视觉层面，从体渲染向高斯分布驱动的实时渲染拓展。尽管各方向已取得显著进展，但整体流程的效率、细节一致性及材质表现力仍存在割裂。本项目整合了三大方向的代表性成果，提出端到端、自洽闭环的解剖约束三维动物建模方法，为实现结构合理、细节真实、运行高效的智能建模与可视化奠定坚实基础。

参考文献：

[1] 国务院. 国务院关于印发新一代人工智能发展规划的通知: 国发〔2017〕35 号[A/OL]. (2017-07-08)[2025-11-27]. https://www.gov.cn/zhengce/content/2017-07/20/content_5211996.htm.

[2] 中共中央 国务院印发《“健康中国 2030”规划纲要》[A/OL]. [2025-11-27]. https://www.gov.cn/gongbao/content/2016/content_5133024.htm.

[3] 2025 年中国宠物行业市场报告 - 毕马威中国[EB/OL]. [2025-11-27]. https://kpmg.com/cn/zh/home/insights/2025/06/2025-china-pet-industry-market-report.html.

[4] AN L, LYU J, LIN L, 等. AniMer+: Unified Pose and Shape Estimation Across Mammalia and Aves via Family-Aware Transformer[A/OL]. arXiv, 2025[2025-11-27]. http://arxiv.org/abs/2508.00298. DOI:10.48550/arXiv.2508.00298.

[5] LIU X, GONG C, LIU Q. Flow Straight and Fast: Learning to Generate and Transfer Data with Rectified Flow[A/OL]. arXiv, 2022[2025-11-04]. http://arxiv.org/abs/2209.03003. DOI:10.48550/arXiv.2209.03003.

[6] GUÉDON A, LEPETIT V. Gaussian Frosting: Editable Complex Radiance Fields with Real-Time Rendering[A/OL]. arXiv, 2024[2025-11-27]. http://arxiv.org/abs/2403.14554. DOI:10.48550/arXiv.2403.14554.

[7] ZUFFI S, KANAZAWA A, JACOBS D, 等. 3D Menagerie: Modeling the 3D shape and pose of animals[EB/OL]. (2016-11-23)[2025-11-27]. https://arxiv.org/abs/1611.07700v2.

[8] BIGGS B, BOYNE O, CHARLES J, 等. Who Left the Dogs Out? 3D Animal Reconstruction with Expectation Maximization in the Loop[EB/OL]. (2020-07-21)[2025-11-27]. https://arxiv.org/abs/2007.11110v2. DOI:10.1007/978-3-030-58621-8.

[9] RUEEGG N, ZUFFI S, SCHINDLER K, 等. BARC: Learning to Regress 3D Dog Shape from Images by Exploiting Breed Information[EB/OL]. (2022-03-29)[2025-11-27]. https://arxiv.org/abs/2203.15536v3.

[10] LYU J, ZHU T, GU Y, 等. AniMer: Animal Pose and Shape Estimation Using Family Aware Transformer[EB/OL]. (2024-12-01)[2025-11-27]. https://arxiv.org/abs/2412.00837v2.
[11] NG X L, ONG K E, ZHENG Q, 等. Animal Kingdom: A Large and Diverse Dataset for Animal Behavior Understanding[C/OL]//2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). New Orleans, LA, USA: IEEE, 2022: 19001-19012[2025-11-27]. https://ieeexplore.ieee.org/document/9879959/. DOI:10.1109/CVPR52688.2022.01844.
[12] WAH C, BRANSON S, WELINDER P, 等. The Caltech-UCSD Birds-200-2011 Dataset[J].
[13] POOLE B, JAIN A, BARRON J T, 等. DreamFusion: Text-to-3D using 2D Diffusion[EB/OL]. (2022-09-29)[2025-11-27]. https://arxiv.org/abs/2209.14988v1.
[14] LIN C H, GAO J, TANG L, 等. Magic3D: High-Resolution Text-to-3D Content Creation[A/OL]. arXiv, 2023[2025-11-27]. http://arxiv.org/abs/2211.10440. DOI:10.48550/arXiv.2211.10440.
[15] LIPMAN Y, CHEN R T Q, BEN-HAMU H, 等. Flow Matching for Generative Modeling[A/OL]. arXiv, 2023[2025-11-04]. http://arxiv.org/abs/2210.02747. DOI:10.48550/arXiv.2210.02747.
[16] MILDENHALL B, SRINIVASAN P P, TANCIK M, 等. NeRF: Representing Scenes as Neural Radiance Fields for View Synthesis[EB/OL]. (2020-03-19)[2025-11-27]. https://arxiv.org/abs/2003.08934v2.
[17] KERBL B, KOPANAS G, LEIMKUEHLER T, 等. 3D Gaussian Splatting for Real-Time Radiance Field Rendering[J/OL]. ACM Transactions on Graphics, 2023, 42(4): 1-14. DOI:10.1145/3592433.
[18] GUÉDON A, LEPETIT V. Gaussian Frosting: Editable Complex Radiance Fields with Real-Time Rendering[EB/OL]. (2024-03-21)[2025-11-27]. https://arxiv.org/abs/2403.14554v1.

2. 项目拟解决的关键科学问题，研究内容、总体框架、重点难点、主要目标（此部分为重点阐述内容）

2.1 拟解决的关键科学问题

当前三维数字内容生成（AIGC-3D）正经历从“纯视觉生成”迈向“可交互资产生成”的深刻变革，特别是在结构复杂、几何约束严格的四足动物领域，传统端到端扩散模型普遍面临“结构崩坏”与“纹理失真”的双重瓶颈。本项目立足于“具身智能生成”的核心命题，聚焦三项紧迫且未被系统解决的关键科学问题：

首先，如何在生成过程中有效融合语义驱动的外观想象与严格解剖拓扑的几何结构，解决两者在生成范式中的“正交冲突”？现有扩散模型虽能产出细腻纹理，却缺乏三维先验，极易产生“多头”“断肢”等结构幻觉[1,2]。而参数化模型如 SMAL 虽具刚性约束，却难以表达多样化细节[3,4]。构建一种“显式参数化引导+隐式生成修补”的混合生成机制，打通从

解剖几何到视觉细节的协同建模，是项目的首要挑战。

其次，在生成路径设计上，如何摆脱“从高斯噪声起步”的扩散范式，构建一种从粗糙几何代理（Proxy Mesh）直达高保真资产的确定性生成路径？本项目拟基于最优传输与薛定谔桥理论[5,6]，构建“基于最优传输的条件流匹配（OT-CFM）”生成机制，通过低维结构化潜变量编码，将“粗几何”桥接至“精细纹理”，在大幅减少推理步数的同时实现高效可控生成。

第三，如何在具备骨骼绑定的动态网格上实现毛发等微观结构的物理感还原？非结构化渲染技术如 Gaussian Frosting 已在静态场景中展现高保真效果[7-9]，但尚缺乏面向生成任务的自适应控制机制。如何建立从语义特征到物理属性的可微映射，实现毛发的自动化过程化生长与动态绑定一致性，是本项目在表达层面的关键技术难题。

2.2 研究内容与技术方案

围绕上述科学问题，项目设计三大技术模块，形成从“几何构型”到“生成细化”再到“视觉表现”的渐进式技术链：

首先，在几何代理阶段，项目拟构建基于专家混合机制（MoE）的鲁棒几何起点，通过改造 AniMer+ 网络[10,11]，实现从图像（及后续可扩展的文本提示）到 SMAL 参数空间的高精度回归，输出带有完整拓扑结构的粗网格（Base Mesh）。该阶段重点强化模型的跨物种适应性与极端姿态容忍度，为后续生成提供稳定可靠的结构锚点。

其次，在生成细化阶段，项目将设计一种结构化潜变量驱动的 OT-CFM 条件流匹配模型[5]，构建从 Proxy 分布到 Ground Truth 分布的最优传输路径。算法采用残差场学习范式，借助稀疏体素/点云编码与几何-纹理联合潜空间，对高频形体细节和表观纹理进行联合预测。同时引入多视角一致性蒸馏（Consistent Flow Distillation），利用预训练扩散/视频生成模型提供跨视角几何与外观约束，确保生成过程在空间结构上的一致性与细节表达的稳定性。

最后，在混合渲染阶段，项目将网格锚定的高斯体渲染机制嵌入生成流程[8]，实现基于模糊度图的高斯原语自动生成与骨骼驱动绑定机制。通过可微渲染接口，联动高斯原语参数与基础网格的运动状态，使毛发资产在动态下保持与骨架变形的一致运动、高保真外观和良好的编辑友好性[8,9]，推动生成结果从“静态精细”迈向“动态真实”。

2.3 总体框架设计

项目整体架构遵循“结构先验 → 流式生成 → 表现增强”的三阶段技术路径：

1. 结构构型（Geometric Proxy）：
从单张图像出发，基于 ViT-MoE 骨架网络提取语义与形态特征[12,13]，回归 SMAL 参数生成拓扑完整、解剖约束合理的粗几何结构，为后续细化提供统一几何坐标系[11]。

2. 流式细化（Flow Refinement）：
基于 OT-CFM 条件流匹配机制[5]，将结构化潜变量输入到最优传输框架中，在粗几何流形与高精几何-纹理流形之间学习确定性的 data-to-data 生成路径，实现几何细节与纹理信息的联合增强，并通过多视角一致性蒸馏提升三维一致性。

3. 视觉呈现（Appearance Realization）：
通过生成模糊度图驱动过程化毛发生成系统，在网格近表面自适应布置高斯原语[8]，并将其

与骨架网格动态绑定，实现毛发在动画状态下的自然展现与高效渲染，构建面向医疗沟通与教学的三维交互视诊界面。

对比维度	传统/现有主流方法 (Existing SOTA) (基于 SDS / NeRF / 纯优化)	本文提出方法 (Proposed Framework) (结构先验 + 流式生成 + 表现增强)
几何构型 (Geometric)	隐式表达 (Implicit) • 基于 SDF 或 NeRF 密度场 • 缺乏解剖学约束，易产生畸变 • 难以精确控制骨骼姿态	参数化先验 (Geometric Proxy) • 核心：ViT-MoE + SMAL 参数回归 • 优势：拓扑完整，解剖约束合理 • 提供统一几何坐标系
生成机制 (Generation)	蒸馏优化 (Distillation) • 基于 SDS (Score Distillation) • 路径：Noise-to-Data (随机性大) • 缺陷：收敛慢，多头效应 (Janus)	流式细化 (Flow Refinement) • 核心：OT-CFM (最优传输流匹配) • 路径：Data-to-Data (确定性路径) • 优势：几何纹理联合增强，多视角一致
视觉呈现 (Appearance)	体积渲染 (Volumetric) • 传统 Mesh 或 NeRF 体积渲染 • 表面平滑，缺乏高频细节 • 毛发渲染计算昂贵，交互困难	表现增强 (Appearance Realization) • 核心：高斯原语 + 过程化毛发系统 • 机制：模糊度图驱动 + 骨架动态绑定 • 优势：支持医疗级交互与动画视诊

图 8 现有主流方法与本文方法在几何重建、生成机制及视觉呈现上的多维度对比

2.4 技术重点与难点攻关

本项目在理论建模与系统实现层面，均面临具有挑战性的创新任务：

重点在于在结构化 3D 潜空间上建立数据－对－数据（Data-to-Data）形式的基于最优传输的条件流匹配（OT-CFM）场[5]。与传统从高斯噪声出发的无条件扩散/流模型不同，项目需在 Proxy 分布与 Target 分布之间构建带有显式条件的残差流映射路径，使几何－纹理细化过程具备良好的可控性与可解释性。

难点一：稀疏 3D 特征空间中的高效编码与 OT-CFM 条件流匹配。
在稀疏 3D 特征空间（如体素、点云或隐式场）内进行 OT-CFM 条件流匹配，需要在有限 GPU 显存约束下实现高分辨率的几何与纹理表达。本项目需设计轻量级的结构化三维表示机制（如 Tri-plane 特征表示或稀疏体素网格），并探索与条件流网络天然兼容的编码－解码结构[7]。同时，引入类似极线/极几何约束的注意力机制，以在多视角采样下保持潜空间表示的跨视角一致性，避免细节在视角变化中发生漂移或失真。

难点二：混合表示在动态形变下的耦合一致性。
在“网格 + 高斯原语”的混合表示下，所有高斯原语的生成位置与尺度必须对动画网格保持紧耦合，在大幅姿态变化和形体调整时仍避免穿模、漂移和毛发断裂等现象[7]。本项目需设计鲁棒的局部锚定机制（例如基于三角面棱柱与重心坐标的绑定策略）与动态密度/厚度调控算法，使高斯原语在网格驱动变形下能够稳定随动，同时兼顾实时渲染效率与画面质量。

2.5 项目主要目标

本项目将兼顾理论创新、系统实现与可应用性三重目标，具体包括：

1. 理论层面

建立一种基于最优传输的条件流匹配（OT-CFM）的确定性 3D 生成新范式，在收敛效率和推理步数上显著优于传统扩散模型，并在几何与纹理生成质量上达到可比甚至更优的水平，力争形成可在 CVPR/ICCV 等计算机视觉顶级会议投稿的完整理论与算法体系。

2. 系统层面

完成端到端 3D 动物生成原型系统，实现单图输入条件下，从骨骼结构预测、粗几何构型到高精几何细化与毛发资产生成的完整推理流程；在单卡 GPU 环境下，将 OT-CFM 推理的 ODE 步数控制在约 2-4 步，满足交互式应用场景的时延要求。

3. 资产质量

生成的三维动物模型需具备可用的骨骼绑定能力，在姿态精度、关节运动合理性、毛发真实感以及多视角外观一致性等指标上，力争在相关公开基准上接近当前 SOTA 方法的水平，为后续医疗可视化与教学应用提供可用的高质量资产基础。

4. 开源与落地

构建并开源涵盖多物种的 3D 动物资产库，发布完整训练/推理代码库及面向 Blender / Unity 等主流内容制作和引擎平台的插件接口，打通从 AI 生成到产业应用的“最后一公里”，为宠物医疗可视化和相关数字内容生产提供可复用的基础设施。

参考文献：

[1] POOLE B, JAIN A, BARRON J T, 等. DreamFusion: Text-to-3D using 2D Diffusion[EB/OL]. (2022-09-29)[2025-11-27]. https://arxiv.org/abs/2209.14988v1.

[2] LIN C H, GAO J, TANG L, 等. Magic3D: High-Resolution Text-to-3D Content Creation[A/OL]. arXiv, 2023[2025-11-27]. http://arxiv.org/abs/2211.10440. DOI:10.48550/arXiv.2211.10440.

[3] XU J, ZHANG Y, PENG J, 等. Animal3D: A Comprehensive Dataset of 3D Animal Pose and Shape[A/OL]. arXiv, 2024[2025-12-10]. http://arxiv.org/abs/2308.11737. DOI:10.48550/arXiv.2308.11737.

[4] ZUFFI S, KANAZAWA A, JACOBS D, 等. 3D Menagerie: Modeling the 3D shape and pose of animals[EB/OL]. (2016-11-23)[2025-11-27]. https://arxiv.org/abs/1611.07700v2.

[5] LIPMAN Y, CHEN R T Q, BEN-HAMU H, 等. Flow Matching for Generative Modeling[EB/OL]. (2022-10-06)[2025-11-27]. https://arxiv.org/abs/2210.02747v2.

[6] BORTOLI V D, THORNTON J. Diffusion Schrödinger Bridge with Applications to Score-Based Generative Modeling[J].

[7] KERBL B, KOPANAS G, LEIMKUEHLER T, 等. 3D Gaussian Splatting for Real-Time Radiance Field Rendering[J/OL]. ACM Transactions on Graphics, 2023, 42(4): 1-14. DOI:10.1145/3592433.

[8] GUÉDON A, LEPETIT V. Gaussian Frosting: Editable Complex Radiance Fields with Real-Time Rendering[A/OL]. arXiv, 2024[2025-11-27]. http://arxiv.org/abs/2403.14554. DOI:10.48550/arXiv.2403.14554.

[9] LIAO Z, XU Y, LI Z, 等. HHAvatar: Gaussian Head Avatar with Dynamic Hairs[EB/OL]. (2023-12-05)[2025-12-10]. https://arxiv.org/abs/2312.03029v3.

[10] LYU J, ZHU T, GU Y, 等. AniMer: Animal Pose and Shape Estimation Using Family Aware Transformer[EB/OL]. (2024-12-01)[2025-11-27]. https://arxiv.org/abs/2412.00837v2.

[11] AN L, LYU J, LIN L, 等. AniMer+: Unified Pose and Shape Estimation Across Mammalia and Aves Via Family-Aware Transformer[J/OL]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2025: 1-18. DOI:10.1109/TPAMI.2025.3633828.

[12] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, 等. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale[A/OL]. arXiv, 2021[2025-12-10]. http://arxiv.org/abs/2010.11929. DOI:10.48550/arXiv.2010.11929.

[13] RIQUELME C, PUIGCERVER J, MUSTAFA B, 等. Scaling Vision with Sparse Mixture of Experts[A/OL]. arXiv, 2021[2025-12-10]. http://arxiv.org/abs/2106.05974. DOI:10.48550/arXiv.2106.05974.

3. 【理工医科】**拟采取的研究方案及可行性分析**（包括研究方法、技术路线、实验手段、关键技术等说明）；【哲学社会学科】**思路方法**（本课题研究的基本思路、具体研究方法、研究计划及其可行性等）

3.1 研究方案与技术路线

3.1.1 总体思路与三阶段架构

本项目面向“单视图输入—高保真三维动物生成”的任务，将整体问题分解为三个相互耦合、但在流形空间上层层递进的子任务：

1. 生物约束的几何基体估计（Stage 1）：
   基于 AniMer/AniMer+ 提出的家族感知 Vision Transformer + Mixture-of-Experts (ViT-MoE) 架构，从单张动物图像（或图像 + 文本提示）直接回归 SMAL 参数 (β, θ, γ)，得到拓扑固定、解剖结构合理的四足动物网格 $\mathbf{M}_{\text{proxy}}$ [1]。该阶段将原始像素空间 $\mathcal{X}$ 映射到“参数化几何流形” $\mathcal{M}_{\text{SMAL}}$。
2. 基于最优传输的条件流匹配（OT-CFM）的几何–纹理流形桥接（Stage 2）：
   设计结构化 3D 潜空间 $\mathcal{Z}$，将 SMAL 网格编码为粗几何潜码 $\mathbf{z}_0 \in \mathcal{Z}$，并构建对应的高精细三维形体/纹理分布 $\mathbf{z}_1 \in \mathcal{Z}$。在此基础上，引入整流流匹配（Rectified Flow）与最优传输（OT）耦合策略，学习一个时间依赖向量场 $\mathbf{v}_\theta(\mathbf{z}, \mathbf{t}, \mathbf{c})$，实现从 $\mathbf{z}_0$ 到 $\mathbf{z}_1$ 的数据对桥接，在极少积分步内完成确定性细化[2]。
3. 基于 Gaussian Frosting 的可编辑毛发体渲染（Stage 3）[3]：
   将 Stage 2 输出的高精细网格 $\mathbf{M}_{\text{high}}$ 与材质信息映射为一个带有 Frosting 层的“网格 + 高斯体”混合表示：在网格周围构造一层厚度可变的体积带，并按 Gaussian Frosting 中的棱柱单元 + 重心坐标参数化方式布置 3D 高斯原语，实现毛发体积、软质材料等复杂外观的高效渲染与动画一致性。

整体上，本项目在三种流形之间完成跨域映射与桥接：

$$\mathcal{X}_{\text{img/text}} \xrightarrow{\text{Stage 1}} \mathcal{M}_{\text{SMAL}} \xrightarrow{\text{Stage 2 (OT-CFM)}} \mathcal{M}_{\text{high-geo/tex}} \xrightarrow{\text{Stage 3 (Frosting)}} \mathcal{R}_{\text{render}}$$

在保持拓扑一致与解剖约束的前提下，引入现代生成流模型和高斯体渲染技术，实现高保真、可编辑、可动画的三维动物生成。

3.1.2 阶段一：基于专家混合机制的生物约束几何估计（AniMer+）

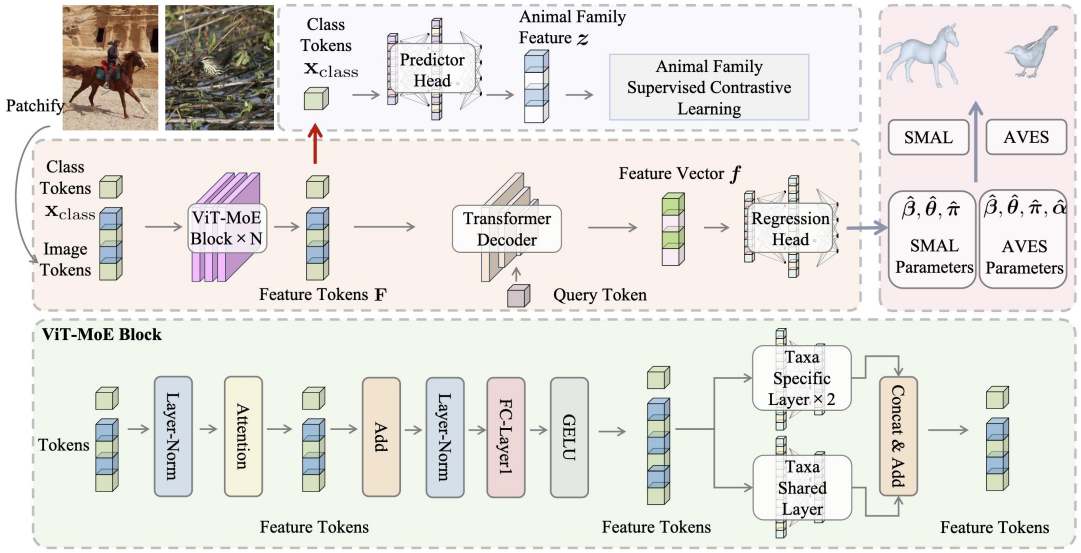


图 9 AniMer+ 网络架构示意图[4]

（1）输入模态与家族感知 ViT-MoE 骨干

输入为单张 RGB 图像 $I \in \mathbb{R}^{H\times W\times 3}$（可扩展为图像 + 文本嵌入）。将图像划分为 N 个 patch，经线性投影得到 patch token 序列：

$$X_0 = [x_1, \ldots, x_N] \in \mathbb{R}^{N\times d}$$

并引入一个 class token x_{cls}，拼接后输入到 Vision Transformer backbone：

$$X_0^{'} = [x_{cls}, x_1, \ldots, x_N]$$

在第 l 层 Transformer 中，AniMer+ 引入轻量级 gating 网络 $G^{(l)}(\cdot)$ 对应 K 个专家子网络 $\{f_k^{(l)}\}_{k=1}^{K}$。对于当前层输入特征 $h^{(l)}$，路由权重为：

$$\alpha_k^{(l)} = \frac{\exp\left(g_k^{(l)}(h^{(l)})\right)}{\sum_{j=1}^{K}\exp\left(g_j^{(l)}(h^{(l)})\right)}, \quad k = 1, \ldots, K$$

输出为加权专家聚合：

$$h^{(l+1)} = \sum_{k=1}^{K} \alpha_k^{(l)} f_k^{(l)}(h^{(l)})$$

其中，不同专家在训练过程中自动对不同动物家族（如犬科、猫科、马科、牛科等）形成形态专长，结合 AniMer 中提出的“动物家族监督对比损失”，利用 class token 的分布使同一生物家族在特征空间中聚类，从而显式引入生物分类先验。

Transformer 最后一层输出的 class token 特征 $h_{cls} \in \mathbb{R}^d$ 以及汇聚的 patch token 特征

$\bar{h}_{patch}$ 共同作为几何回归头的输入。

（2）SMAL 参数化模型与“几何骨架”生成

四足动物几何采用 SMAL（Skinned Multi-Animal Linear Model）参数化模型表示。SMAL 将动物网格顶点 $V \in \mathbb{R}^{N_v \times 3}$ 视为形状基向量的线性组合并配合骨骼蒙皮实现姿态变形，可形式化为：

$$V(\beta, \theta, \gamma) = W(B(\beta, \theta), J(\beta), \theta, \gamma)$$

其中：

- $\beta \in \mathbb{R}^{d_\beta}$ 为形状系数（论文中 $d_\beta \approx 40$），控制体型差异；
- $\theta \in \mathbb{R}^{d_\theta}$ 为关节旋转参数（如 24 关节，每个 3 自由度）；
- $\gamma \in \mathbb{R}^6$ 为全局位姿（平移 + 旋转）；
- $B(\beta, \theta)$ 给出蒙皮前的“模板 + 形状 + 姿态”顶点；
- $J(\beta)$ 为形状相关的骨骼关节位置；
- $W(\cdot)$ 为线性蒙皮函数（LBS）。

本项目中，基于 h_{cls} 和 $\bar{h}_{patch}$ 构建一个多层感知机回归头：

$$[\hat{\beta}, \hat{\theta}, \hat{\gamma}] = f_{MLP}([h_{cls} \| \bar{h}_{patch}])$$

再经 SMAL 模型得到预测网格：

$$M_{proxy} = V(\hat{\beta}, \hat{\theta}, \hat{\gamma})$$

其拓扑结构固定，天然满足“四肢数量正确、不出现自交拓扑错误”等解剖约束，构成后续细化的几何骨架。

（3）损失函数与训练策略

参考 AniMer+ 的两阶段训练策略，结合多源 3D/2D 标注数据，构建如下损失：

- (a) 三维监督损失（3D Loss）（针对有 3D 标注的数据，如 Animal3D, CtrlAni3D）：

$$\mathcal{L}_{3D} = \lambda_\beta \| \hat{\beta} - \beta \|_2^2 + \lambda_\theta \| \hat{\theta} - \theta \|_2^2 + \| \hat{K}_{3D} - K_{3D} \|_1$$

其中 $\hat{K}_{3D}$ 与 K_{3D} 为预测/真值 3D 关键点坐标，$\lambda_\beta, \lambda_\theta$ 为权重。

- (b) 二维重投影损失（2D Loss）（针对仅有 2D 关键点的数据，如 Animal Pose, APT-36K, Animal Kingdom 等）：

$$\mathcal{L}_{2D} = \| \pi(\hat{K}_{3D}) - K_{2D} \|_1$$

其中 $\pi(\cdot)$ 为透视投影算子，K_{2D} 为标注关键点。

- (c) 形状－姿态先验损失（Prior Loss）：利用 SMAL 提供的高斯先验 $(\mu_\beta, \Sigma_\beta), (\mu_\theta, \Sigma_\theta)$，通过马氏距离约束参数落在合理解剖分布内：

$$\mathcal{L}_{\text{prior}} = \lambda_\beta(\hat{\beta} - \mu_\beta)^\top \Sigma_\beta^{-1}(\hat{\beta} - \mu_\beta) + (\hat{\theta} - \mu_\theta)^\top \Sigma_\theta^{-1}(\hat{\theta} - \mu_\theta)$$

- (d) 对抗损失（Adversarial Loss）：采用类似 HMR 的判别器 $\mathbf{D_k}$，约束预测参数的整体分布接近真实动物姿态空间：

$$\mathcal{L}_{\text{adv}} = \sum_k (\mathrm{D_k}(\hat{\theta}, \hat{\beta}) - 1)^2$$

综合损失为：

$$\mathcal{L}_{\text{Stage1}} = \mathcal{L}_{\text{3D}} + \lambda_{\text{2D}}\mathcal{L}_{\text{2D}} + \lambda_{\text{prior}}\mathcal{L}_{\text{prior}} + \lambda_{\text{adv}}\mathcal{L}_{\text{adv}}$$

通过汇聚 7 个公开 2D/3D 动物数据集与自建 CtrlAni3D 合成数据，AniMer 已在 Animal3D、CtrlAni3D 及 Animal Kingdom 上取得当前最优的 PA-MPVPE / PA-MPJPE 指标，证明该阶段方案可以提供稳健的几何基体，为后续流形细化提供可靠输入。

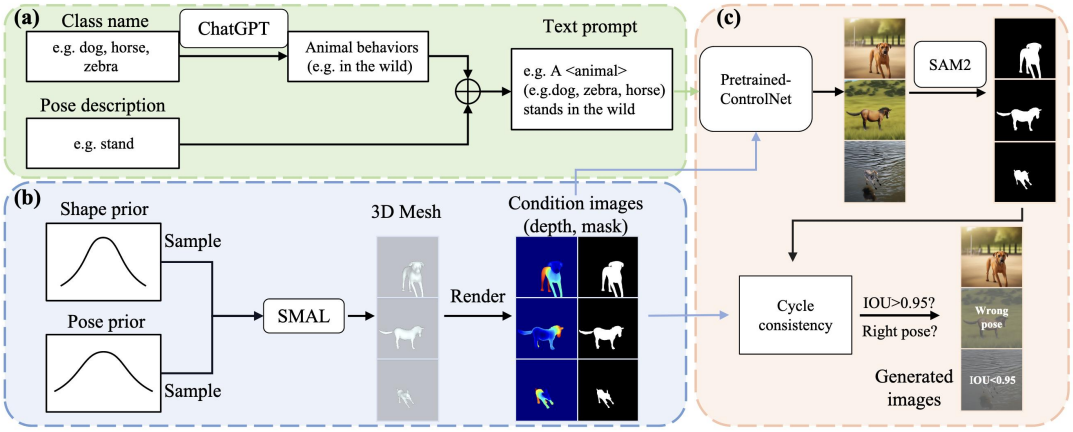


图 10 CtrlAni3D 数据集生成流程[4]

3.1.3 阶段二：基于最优传输的条件流匹配（OT-CFM）的几何 - 纹理流形桥接

本阶段目标是将 Stage 1 得到的“低频几何流形”上的样本 $\mathbf{M_{proxy}}$ 映射到“高频几何+纹理流形”上的样本 $\mathbf{M_{high}}$，并在潜空间中形成粗 - 精两种分布之间的确定性“数据 - 对 - 数据”流形桥接[2]。

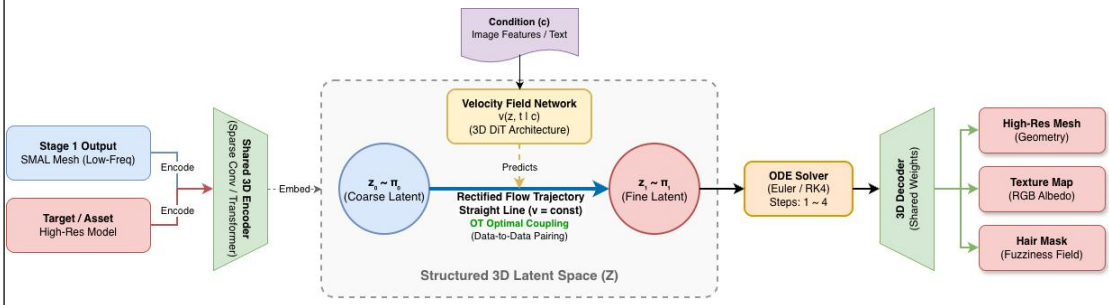


图 11 阶段二 OT-CFM 结构化潜空间与粗 - 精分布桥接机制示意图

（1）SMAL 网格到结构化 3D 潜空间的编码

将预测的 SMAL 网格 $\mathbf{M}_{\text{proxy}}$ 通过 3D 编码器 $\mathcal{E}$ 映射到结构化 3D 潜空间 $\mathcal{Z}$：

1. 先在包围盒 $\Omega \subset \mathbb{R}^3$ 上构建规则体素网格（或点云），编码几何属性（如占据、SDF、法向、骨骼权重等），得到输入张量 $\mathbf{X}_{\text{vox}} \in \mathbb{R}^{C_{\text{in}} \times D \times H \times W}$；
2. 经稀疏 3D 卷积 / 3D Transformer 得到潜表示：

$$\mathbf{z}_0 = \mathcal{E}(\mathbf{M}_{\text{proxy}}) \in \mathcal{Z} \subset \mathbb{R}^{C \times D' \times H' \times W'}$$

类似地，对高精度动物模型 $\mathbf{M}_{\text{high}}$（来自高精度 3D 资产库或离线重建）经同一编码器得到：

$$\mathbf{z}_1 = \mathcal{E}(\mathbf{M}_{\text{high}})$$

由此得到粗 - 精潜码样本对 $(\mathbf{z}_0, \mathbf{z}_1)$，定义粗分布 π_0 与精分布 π_1 在 $\mathcal{Z}$ 上的经验分布。

（2）Rectified Flow（整流流）匹配的数学模型

Rectified Flow 的核心思想是：直接在数据对 $(\mathbf{z}_0, \mathbf{z}_1)$ 上学习一族“尽可能直”的连续时间流，避免传统扩散模型从噪声出发的高曲率轨迹[2]。

令 γ 为 π_0, π_1 的一个耦合（coupling），即 γ 是 $\mathcal{Z} \times \mathcal{Z}$ 上的联合分布，边缘分布分别为 π_0, π_1。对每个样本对 $(\mathbf{z}_0, \mathbf{z}_1) \sim \gamma$，构造线性插值路径：

$$\psi_t(\mathbf{z}_0, \mathbf{z}_1) = (1 - t)\,\mathbf{z}_0 + t\,\mathbf{z}_1, \quad t \in [0,1]$$

其“理想速度场”为：

$$\mathbf{u}(\mathbf{z}_0, \mathbf{z}_1) = \mathbf{z}_1 - \mathbf{z}_0$$

即在整个时间轴上保持常数速度即可完成从 $\mathbf{z}_0$ 到 $\mathbf{z}_1$ 的最短路径（在欧氏度量下）。

我们用一个条件向量场 $\mathbf{v}_\theta(\mathbf{z}, t, \mathbf{c})$（如 3D DiT 结构）来近似该理想速度，其中 $\mathbf{c}$ 为条件（来自 Stage 1 的图像特征、类别标签等）。训练目标为 Rectified Flow（整流流）匹配损失：

$$\mathcal{L}_{\text{FM}}(\theta) = \mathbb{E}_{(\mathbf{z}_0, \mathbf{z}_1) \sim \gamma}\, \mathbb{E}_{t \sim \mathcal{U}(0,1)} [\, \| \mathbf{v}_\theta(\psi_t(\mathbf{z}_0, \mathbf{z}_1), t, \mathbf{c}) - (\mathbf{z}_1 - \mathbf{z}_0) \|_2^2]$$

在训练收敛时，$\mathbf{v}_\theta$ 近似满足：

$$\frac{d\mathbf{z}_t}{dt} = \mathbf{v}_\theta(\mathbf{z}_t, t, \mathbf{c}), \quad \mathbf{z}_{t=0} \sim \pi_0$$

的解满足 $\mathbf{z}_{t=1} \sim \pi_1$，且轨迹接近直线，从而在推理阶段可以用非常少的 ODE 步长（如 Euler / RK4，仅 1 - 4 步）将 $\mathbf{z}_0$ 映射到 $\mathbf{z}_1$ 对应的高精样本。

与传统“噪声 → 数据”的扩散模型不同，本项目在 “数据 → 数据” 的结构化潜空间中直接学习 $\pi_0 \to \pi_1$ 的映射，更适合解决“几何粗模 → 高精模型”的流形桥接问题。

（3）引入最优传输耦合的粗 - 精匹配（OT-Coupled Flow Matching）

为了避免随机配对造成的“大跨距”变形，本项目在批量样本上引入最优传输理论，以近似求解以二次代价 $c(z_0, z_1) = \| z_0 - z_1 \|_2^2$ 为目标的最优耦合 γ^*：

- 在每个 mini-batch 中，采样粗潜码集合 $\{z_0^i\}_{i=1}^B$ 与精潜码集合 $\{z_1^j\}_{j=1}^B$，构建代价矩阵：

$$C_{ij} = \| z_0^i - z_1^j \|_2^2$$

- 采用 Sinkhorn 算法求解近似最优传输计划 $P^* \in \mathbb{R}^{B \times B}$，满足行/列归一约束；

- 从 P^* 中抽取高概率匹配对 $(z_0^i, z_1^{\pi(i)})$ 作为训练样本对，构成经验耦合 γ_{OT}。

这样得到的配对往往在语义与几何上更接近（“猫－猫”、“马－马”、局部姿态相近等），从而显著降低流场的曲率，使得 Rectified Flow（整流流）更接近理论上的直线解，也更利于少步长推理。

（4）几何－纹理级联细化与多视图一致性约束

为了更好地控制高频信息的注入，本项目在潜空间中采用通道分解 + 级联流的方式：

- 将潜码分解为几何主导通道和外观/纹理通道：

$$z = [z^{geo}, z^{tex}]$$

- 初始阶段仅在 z^{geo} 上训练流场 v_θ^{geo}，重点学习几何细节（肌肉、耳廓、四肢粗细等）的变形；

- 在几何流稳定后，引入 z^{tex} 通道训练 v_θ^{tex}，条件中加入 Stage 1/2 的图像特征，使纹理与输入图像外观保持一致（如毛色、花纹）。

多视图一致性方面，结合 Stage 3 的可微渲染，我们可在训练中对同一 3D 模型渲染多视角 $\{I_v\}$，并加入重投影与感知一致性约束：

$$\mathcal{L}_{\text{multi-view}} = \sum_v \| \mathcal{R}(M_{high}, v) - I_v \|_2^2 + \lambda_{perc} \mathcal{L}_{perc}(\mathcal{R}(M_{high}, v), I_v)$$

其中 $\mathcal{R}$ 为可微渲染器（可共享 Stage 3 的高斯渲染管线）。

最终，经过解码器 $\mathcal{D}$：

$$(\widetilde{M}_{high}, T_{base}, M_{fuzz}) = \mathcal{D}(z_{ref})$$

得到：

- 高精细网格 $\widetilde{M}_{high}$（可视作在 SMAL 拓扑上加位移的细分网格）；

- 基础纹理贴图 T_{base}（漫反射、法线等）；

- 毛发模糊度掩码 $M_{fuzz} \in [0,1]$（定义毛发区域与厚度）。

3.1.4 阶段三：基于 Gaussian Frosting 的可编辑毛发体渲染

本阶段将 Stage 2 输出的高精细网格视作 Gaussian Frosting 的基础网格，在其周围

构造一层厚度随材质变化的 Frosting 体积层，并在其中布置大量 3D 高斯原语，实现毛发体积和软质材质的真实感渲染与实时动画[3]。

（1）Frosting 层与毛发区域构建

给定基础网格 $M_{high} = (V, F)$ 与每个顶点的单位法向 $\{n_i\}$，以及由 Stage 2 输出的毛发模糊度 $M_{fuzz}(v_i) \in [0,1]$。我们参考 Gaussian Frosting 中的“内/外偏移面”思想，为每个顶点定义内外偏移量 $\delta_i^{in}, \delta_i^{out}$：

$$v_i^{in} = v_i + \delta_i^{in} n_i, \quad v_i^{out} = v_i + \delta_i^{out} n_i$$

在本项目中，$\delta_i^{in}, \delta_i^{out}$ 由模糊度与标定厚度函数控制，例如：

$$\delta_i^{in} = -\alpha\, M_{fuzz}(v_i), \quad \delta_i^{out} = \beta\, M_{fuzz}(v_i)$$

其中 $\alpha, \beta > 0$ 与毛发最大长度相关。无毛发区域（$M_{fuzz} \approx 0$）对应近零厚度，仅保留薄层用于纹理细节。所有三角面在 $\{v_i^{in}\}, \{v_i^{out}\}$ 上生成局部三棱柱体，铺成一层厚度随材质变化的 Frosting 体积层。

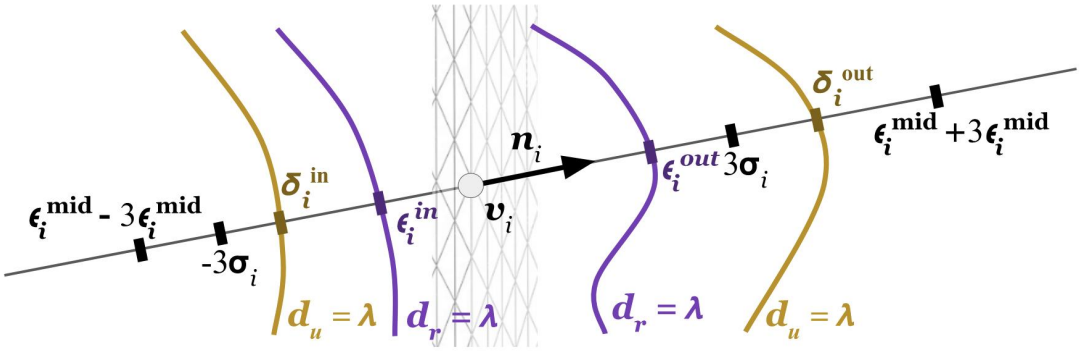


图 12 Frosting 层几何定义与三棱柱单元构建示意图[3]

（2）基于棱柱单元与重心坐标的高斯参数化及动画一致性

对每个三角面 (v_0, v_1, v_2) 及其对应的内/外偏移顶点 (v_i^{in}, v_i^{out}) 构成一个不规则三棱柱单元。参考 Gaussian Frosting 的参数化，对每个高斯中心 μ_g 使用六个重心坐标 $\{b_g^{(i)}, \beta_g^{(i)}\}_{i=0}^{2}$ 表示：

$$\mu_g = \sum_{i=0}^{2} \left(b_g^{(i)} (v_i^{out}) + \beta_g^{(i)} (v_i^{in}) \right), \quad \sum_{i=0}^{2} \left(b_g^{(i)} + \beta_g^{(i)} \right) = 1$$

通过对 $\{b_g^{(i)}, \beta_g^{(i)}\}$ 做 softmax 归一，可保证所有高斯中心始终位于对应棱柱内部，从而在优化与动画过程中保持数值稳定。每个高斯还携带协方差矩阵 Σ_g、不透明度 α_g 以及球谐系数 c_g（表征视角相关颜色），构成完整参数集：

$$G = \{\mu_g, \Sigma_g, \alpha_g, c_g\}_{g=1}^{N}$$

由于网格顶点在动画中通过 SMAL 骨骼进行线性蒙皮，顶点位置 v_i 发生仿射变换 $T(v_i)$ 时，对应的 v_i^{in}, v_i^{out} 也随之变换，高斯中心根据上述重心组合自动更新。Gaussian Frosting 进一步提供了利用棱柱六个顶点局部变换估计高斯旋转与缩放更新的策略，从而

在整体动画时保持毛发体积方向与尺度的一致性，而无需显式物理模拟。

（3）差分渲染与实例级外观微调

渲染阶段采用与 3D Gaussian Splatting 一致的体渲染公式：对每个视角 $\mathbf{v}$ 下的像素 $\mathbf{p}$，从远到近累加高斯贡献：

$$\hat{\mathbf{I}}(\mathbf{p}) = \sum_{\mathbf{g}\in\mathcal{G}(\mathbf{p})} \mathbf{T}_{\mathbf{g}}(\mathbf{p})\,\mathbf{C}_{\mathbf{g}}(\mathbf{p})$$

其中 $\mathbf{T}_{\mathbf{g}}(\mathbf{p})$ 为累积透射率，$\mathbf{C}_{\mathbf{g}}(\mathbf{p})$ 由高斯的球谐颜色 $\mathbf{c}_{\mathbf{g}}$ 与入射方向共同决定，$\mathcal{G}(\mathbf{p})$ 为沿视线可见的高斯集合。

为了使生成结果与输入图像在像素级对齐，本项目在推理阶段对单个实例进行轻量的外观微调：固定几何与高斯中心，仅对 $\{\alpha_{\mathbf{g}}, \mathbf{c}_{\mathbf{g}}\}$ 做 50–100 次梯度下降，以最小化输入图像 $\mathbf{I}_{\text{in}}$ 与渲染图像 $\hat{\mathbf{I}}$ 的差异：

$$\mathcal{L}_{\text{photo}} = \sum_{\mathbf{p}} \|\hat{\mathbf{I}}(\mathbf{p}) - \mathbf{I}_{\text{in}}(\mathbf{p})\|_2^2 + \lambda_{\text{perc}}\mathcal{L}_{\text{perc}}(\hat{\mathbf{I}}, \mathbf{I}_{\text{in}})$$

得益于 Frosting 对高斯数量与分布的有效控制，且我们不再从零优化几何，仅微调外观参数，因此该过程计算量远低于完整 3DGS 训练，在保证实时渲染能力的前提下显著提升视觉真实度。

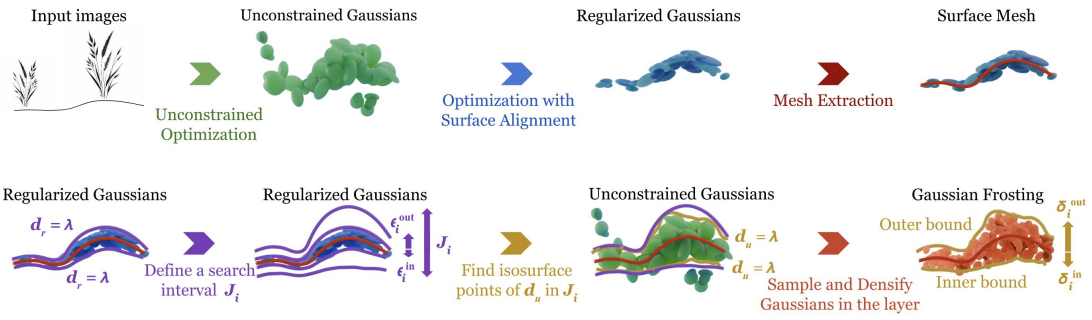


图 13 Gaussian Frosting 附着层的构建流程与几何结构定义[3]

3.1.5 数据集与实验设计

- 几何估计训练数据（Stage 1）
  复用 AniMer/AniMer+ 中构建的多源数据集组合，包括 Animal3D、CtrlAni3D、Zebra Synthetic、Animal Pose、APT-36K、AwA-Pose、StanfordExtra 等，总规模约 4 万张图像，其中含有 SMAL 参数及 3D 关键点标注的数据集（Animal3D、CtrlAni3D、Zebra Synthetic）为 Stage 1 提供强 3D 监督，其余提供 2D 关键点与掩膜。
- 粗–精流形桥接训练数据（Stage 2）
  - 以 CtrlAni3D/Animal3D 中的 SMAL 网格为粗几何，利用形体雕刻、高精重建或隐式表面网络生成对应高精细网格作为 $\mathbf{M}_{\text{high}}$，构造 $(\mathbf{M}_{\text{proxy}}, \mathbf{M}_{\text{high}})$ 对；

- 通过 $\mathcal{E}$ 与 $\mathcal{D}$ 形成 (z_0, z_1) 样本集，为 OT-CFM 训练提供数据基础；
- 在多视图合成场景中，通过渲染得到多视角图像，施加多视图一致性约束。

- 渲染与毛发质量评估数据（Stage 3）
  - 采用 Shelly、Mip-NeRF 360 等包含大量“毛发/绒毛材料”的公开数据集进行对比实验（Frosting 已在这些数据上验证优越性）；
  - 引入真实宠物照片与视频序列，对生成模型进行主观质量评价与三维一致性检验。

- 评估指标与消融实验
  - 几何精度：PA-MPVPE、PA-MPJPE、PCK@0.1/0.15 等；
  - 渲染质量：PSNR、SSIM、LPIPS，与 3DGS/SuGaR/Frosting 原始结果对比；
  - 效率指标：单视图重建时间、可交互帧率（目标 ⩾30 FPS）。
  - 消融：去除 OT 耦合、去除几何-纹理级联、采用 Mesh-only 渲染等，分析各模块贡献。

3.2 可行性分析

3.2.1 理论与方法基础

1. 阶段一的可行性

AniMer 已在 CVPR 2025 中系统验证了“家族感知 Transformer + SMAL”的路线上，在 Animal3D、CtrlAni3D、Animal Kingdom 等多数据集上取得目前最优的 PA-MPVPE/PA-MPJPE 指标，且对 OOD 物种具有良好泛化能力。AniMer+ 在此基础上引入更高容量的 ViT-MoE，并扩展到鸟类，实现跨 Mammalia/Aves 统一重建，说明该方向具备充足的技术储备与开源代码基础。

2. 阶段二的可行性

Rectified Flow 已在图像生成与最优传输问题中被证明能够显著降低推理步数、获得近直线的传输路径；同时，基于 Flow Matching 的 3D 点云/形体生成（如 GaussianAnything 等工作）也展示了在三维流形上的可行性。本项目将这些方法从“噪声 → 数据”的范式转化为“粗几何 → 精细几何/纹理”的数据-对-数据流形桥接，理论上是对现有框架的自然扩展；OT 耦合进一步在批量内寻找“最小形变配对”，可降低流场曲率，使 Rectified Flow（整流流）更适合少步长数值积分。

3. 阶段三的可行性

Gaussian Frosting 在 ECCV 2024 中已证明：在包含大量毛发/绒毛材料的 Shelly、Mip-NeRF 360、Tanks & Temples 等数据集上，其在保持可编辑/可动画网格表示的同时，渲染质量（PSNR、SSIM、LPIPS）可超过甚至接近非可编辑的 Vanilla 3DGS，而且能高效控制高斯数量。
本项目在 Frosting 框架上加入来自 Stage 2 的毛发模糊度掩码与 SMAL 骨骼动画，仅对其进行任务定制化扩展，不会改变其核心收敛性质与实时性优势

3.2.2 数据资源与算力条件

1. 数据资源充足

AniMer+ 已公开 CtrlAni3D 生成流程及多数据集汇总方案，训练集规模在 4 万张左右，且可进一步通过文本提示生成更多具有 SMAL 真值的合成样本，为 Stage 1 和 Stage 2 提供可控的 3D 标注数据。

Animal Kingdom 等大规模 2D 关键点数据集已在文献中用于评价 OOD 能力，其许可下载后可用作弱监督与测试集。

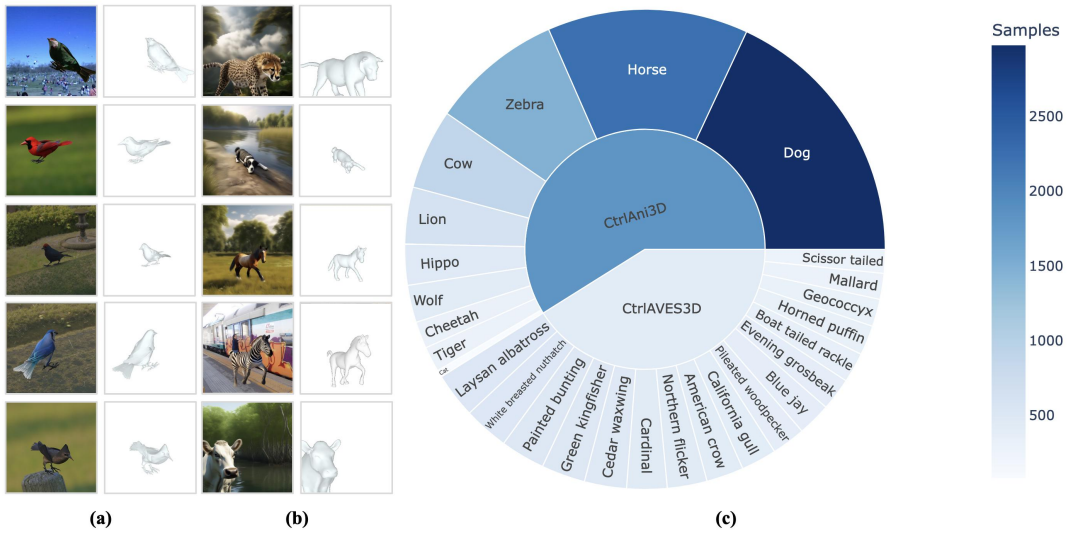


图 14 AniMer+ 公开数据集结构[4]

2. 算力需求可控

AniMer 报告在单张 RTX 4090 上一周左右即可完成训练，这为本项目 Stage 1 的训练时间提供了现实参考。Gaussian Frosting 报告在单卡 V100 上 45–90 分钟即可优化一个场景，而本项目将 Frosting 仅作为“最后一层外观/毛发精修”，不需要进行大规模场景重建，因此总体算力需求在现有 GPU 资源下可满足。

3. 软件与实现基础

Rectified Flow 和 Gaussian Frosting 均提供了公开代码或详细实现说明；AniMer/AniMer+ 使用 PyTorch 实现，与本项目预期开发环境一致，方便复用骨干网络与训练脚本。

3.2.3 研究团队基础与前期工作

本项目团队在以下方向已有实践基础：

- 在单视图 3D 重建与动物网格估计方面，已有基于 SMAL / AniMer 思路的初步实现与实验经验，熟悉 CtrlAni3D 数据管线及 SMAL 参数空间的限制与优点；
- 在生成式流匹配与 ODE 基模型方面已开展前期工作，包括对 Flow Matching/Rectified Flow 的理论阅读与小规模图像任务实验，为 Stage 2 的 OT-CFM 提供算法与工程基础；
- 在 3D Gaussian Splatting 与可微渲染方面，掌握现有开源实现（3DGS、SuGaR、Frosting 等）的原理与代码结构，有能力在其上实现毛发、软组织等领域特化扩展。

因此，在理论理解、算法实现与工程调试三个层面，团队均具备开展本项目的基础。

3.2.4 关键技术风险与应对策略

- 高精细 3D 资产不足的风险
  若真实高精度动物 3D 模型数量有限，将影响 Stage 2 的目标分布 π_1 多样性。
  应对策略：
  - 利用 SMAL 网格在建模软件中进行自动/半自动雕刻，批量生成“伪高精”模型；
  - 通过多视图照片+现有重建方法（如 NeuS/NeRF-based meshing）获得附加高精几何；
  - 采用“先几何后纹理”的分阶段训练，将几何细化优先完成，再逐步丰富纹理。
- OT-CFM 数值稳定性与泛化问题
  OT-CFM 的 ODE 解在少步长条件下需要兼顾稳定性与泛化。
  应对策略：
  - 在训练阶段加入噪声扰动与正则项，控制向量场 Lipschitz 常数；
  - 推理时采用自适应步长的 Runge–Kutta 方法，监控局部截断误差；
  - 若少步长解不稳定，可退化为固定小步长（如 8–16 步）模式，依然远低于扩散模型的数百步。
- 毛发渲染的性能瓶颈
  大量高斯可能带来内存与渲染时间压力。
  应对策略：
  - 借鉴 Frosting 中按场景复杂度自适应分配高斯数量与简易遮挡裁剪（occlusion culling）的策略；
  - 结合项目中 Stage 2 的毛发模糊度掩码与区域重要性评估，只在毛发/边界等关键区域高密度采样高斯，在大面积平滑区域维持低密度；
  - 对远景视角启用层次细节（LOD），减少远处高斯对画面质量的影响。

综合来看，三阶段方案均建立在近年国际前沿工作的扎实基础之上，关键算法已在相关任务中被验证可行；本项目所做的是将这些方法进行有机整合与定制化改造，以适应“解剖约束 + 高保真毛发 + 实时动画”的特定需求。在合理的数据与算力配置下，拟定的研究方案具有明确的实现路径和较高的成功可能性。

参考文献：

[1] AN L, LYU J, LIN L, 等. AniMer+: Unified Pose and Shape Estimation Across Mammalia and Aves via Family-Aware Transformer[A/OL]. arXiv, 2025[2025-11-27]. http://arxiv.org/abs/2508.00298. DOI:10.48550/arXiv.2508.00298.

[2] AN L, LYU J, LIN L, 等. AniMer+: Unified Pose and Shape Estimation Across Mammalia and Aves Via Family-Aware Transformer[J/OL]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2025: 1-18. DOI:10.1109/TPAMI.2025.3633828.

[3] ZUFFI S, KANAZAWA A, JACOBS D, 等. 3D Menagerie: Modeling the 3D shape and pose of animals[EB/OL]. (2016-11-23)[2025-11-27]. https://arxiv.org/abs/1611.07700v2.
[4] LIU X, GONG C, LIU Q. Flow Straight and Fast: Learning to Generate and Transfer Data with Rectified Flow[A/OL]. arXiv, 2022[2025-11-04]. http://arxiv.org/abs/2209.03003. DOI:10.48550/arXiv.2209.03003.
[5] GUÉDON A, LEPETIT V. Gaussian Frosting: Editable Complex Radiance Fields with Real-Time Rendering[EB/OL]. (2024-03-21)[2025-11-27]. https://arxiv.org/abs/2403.14554v1.

3. 本项目的特色与创新点（建议 2-3 点）；

1. 解剖约束、生成流与可编辑表示的一体化新范式

本项目首创性地将 SMAL 参数化骨架、生成式流模型与 Gaussian Frosting 可编辑表示 统一在同一技术框架下：前端以 SMAL 模型为刚性锚点，将兽医解剖先验直接内嵌于网络结构与损失函数中，从源头避免四肢数量错误、骨骼穿模等“结构幻觉”；中间通过流形桥接模块在几何－纹理潜空间中实现从粗几何到高精资产的确定性映射；末端采用可编辑的 Mesh+Gaussians 表示统一承载渲染与动画。相较于传统“仅做几何估计”或“仅做 3D 生成”的工作，本项目提出的是一种覆盖结构先验—细节生成—可视化交互的完整三维生成范式。

2. 面向几何－纹理流形的基于最优传输的条件流匹配（OT-CFM）桥接机制

针对“素模到高保真细节”的关键难题，本项目提出 Optimal Transport Coupled Flow Matching（OT-CFM），在结构化 3D 潜空间中直接学习

$$\pi_0 \ :\text{SMAL 粗几何分布} \ \rightarrow \ \pi_1 \ :\text{高精几何－纹理分布}$$

的确定性 data-to-data 生成算子。通过 Sinkhorn 最优传输在批量内建立粗－精样本对的最小形变配对，并在此基础上采用 Rectified Flow 学习接近直线的时间依赖向量场，实现 1－4 步 ODE 推理即可从粗模生成带细节的高精模型。与现有从高斯噪声出发的随机扩散相比，OT-CFM 在理论上对应“最短路径”的几何－纹理流形桥接，在工程上兼具稳定性、可解释性与高推理效率，是对流匹配范式在 3D 医疗场景中的一次本质扩展。

3. 面向临床视诊的 Gaussian Frosting 三维交互可视化接口

在渲染端，本项目将 Gaussian Frosting 从通用 3D 场景扩展至 兽医影像交互可视化：利用 Stage 2 输出的模糊度/毛发度映射构建厚度可调的 Frosting 层，实现毛发区域与躯干/骨骼的解耦渲染，支持一键“去毛”与局部毛发保留等操作，为临床提供类似“无创透视 + 局部真实”的混合视效。同时，依托 SMAL 骨架驱动 Frosting 层中高斯原语的参数化更新，保证毛发在体型变化与关节活动下与骨骼－皮肤严格同构运动，满足病例级实时旋转、摆姿与动态演示需求。相较传统仅依赖 CT/MRI 切片的三维诊断方式，本项目构建了一种经济可及的 生成式三维视诊界面，在基层宠物医疗场景具有明显的应用创新价值。

（二）研究基础与工作条件

2.**代表性之外成果和奖励**（限合计不超过5项）。

（六）预期成果形式（可多选）

1.☐SCI 论文1篇 2.☐核心期刊论文__篇 3.☑会议论文1篇 4.☐内部编印期刊论文__篇 5.☐授权发明专利__项 6.☑申请发明专利1项 7.☑创新创业类竞赛获奖 8.☐参加国际国内学术交流活动 9.☐其他　　名称：_____

（七）项目经费概要（按申报项目目标任务需要进行预算，经费执行情况将与结题考核成绩挂钩）

1.申请经费明细

（1）仪器设备费 4000

（2）耗材费 1000

（3）测试加工费 500

（4）国内会务及差旅费 3000

（5）国外会务及差旅费 0

（6）文献/知识产权事务费 1000

（7）办公费（含文印、办公用品等） 500

（8）其他费用 0

2.合计 10000